

《强化学习》

强化学习复习课

人工智能系

主讲人：孙俊忍

联系方式：sunjunren@cumtb.edu.cn



课程评分机制 $100 = (20 + 10) + 50 + 20$

- 1个大作业 (20%)
 - 3人一组，运用本门课程所学内容，自由选择解决行业问题。
 - 加分项：1) 矿业相关 2) 运用真实数据。
 - 以探索创新为主，每组产出4+页mini paper、代码和数据附件（总大小<100MB）。放于每组一个的文件夹，文件夹以3人姓名命名。各班收齐后第16次课前统一上交。全部电子版。
 - Mini paper 包括但不限于（问题背景、解决思路、解决方法模型、结果展示、阐述如何运用了本门课内容）。
- 答辩展示（第16次课，10%）：展示大作业内容，2~3min/组
- 笔试考试 (50%)
 - 题型：选择、简答
- 出勤 (20%)



第一讲 强化学习简介

- 决策和预测的不同，举例
- 强化学习的基本概念和定义
- 强化学习系统要素
- 价值和策略近似
- 深度强化学习带来的关键变化
- 深度强化学习的研究前沿有哪些
- 强化学习的落地场景有哪些
- 利用和探索的均衡
- 多臂老虎机问题模型、算法流程、regret函数、贪心和 ϵ 贪心策略、乐观初始化、UCB上置信界、Thompson Sampling方法

理解思想 不需背公式



第二讲 马尔可夫决策过程

- 随机过程和马尔可夫过程的对比
- MDP五元组、累计奖励表达式
- 目标、策略和价值函数的定义
- 价值函数的Bellman等式 ~~式~~
- 价值迭代和策略迭代的过程与对比
- 同步和异步迭代
- 学习模型&优化策略



第三讲 值函数估计

定义

- 无模型的强化学习的含义
- 动态规划计算值函数
- 蒙特卡洛方法定义及举例 大数定律 图形演示
- 蒙特卡洛价值估计实现流程 特点
- 使用重要性采样的离线策略蒙特卡洛、离线策略时序差分
- 时序差分学习 特点、与MC的对比、优缺点对比 对比
- 多步时序差分 n步累计奖励 相似 优点 深度 广度区分



第四讲 无模型控制方法

□ SARSA

- 含义、策略评估与策略改进、了解算法流程

□ Q学习 *解状态-动作值函数*

- 特点、迭代式及含义、 $Q(s_t, a_t)$ 值更新表达式

□ 离线策略学习

- 含义、为什么使用离线策略学习

□ 了解Q学习收敛性证明 (了解即可)

□ 多步自助法: 多步时序差分预测、n步累计奖励、平均 n 步累计奖励、TD(λ) 算法、多步Sarsa、了解使用重要性采样的多步离线学习方法、了解多步树回溯算法

(知道有几种方法)

迭代更新式

*SARSA TD 算法
动作设置参数. 权重*



第五讲 规划与学习

P98 图要会画

□ 策略值函数估计、策略提升含义、策略提升定理 (描述)

□ 模型的含义、分类及作用

□ 规划的含义、通用框架、举例、优势

□ 规划与学习的对比 相同/不同

□ Dyna算法 P205 图要会画 (算法)

$V+K\sqrt{t}$

- 经验的不同用途、框架、了解步骤表格 Dyna - Q算法流程、Dyna-Q+的改进

□ 优先级采样含义

□ 期望更新和采样更新对比

□ 轨迹采样优缺点

加速收敛-采样

□ 实时动态规划、决策时规划 (了解)

□ (了解) 了解启发式搜索、Rollout算法、蒙特卡洛树搜索 (了解)



第六讲 价值和策略近似逼近方法

- 离散化连续马尔可夫决策过程、分桶的含义及优缺点
- 值函数近似的主要形式 *举例*
- 随机梯度下降 (SGD) 的值函数近似 *→ 写出梯度下降的, 参数更新*
- 蒙特卡洛状态值函数近似、蒙特卡洛状态值函数近似 *↑ 要求相同*
- 状态-动作值函数近似、时序差分的状态-动作值函数近似
- 参数化策略的含义
- 基于策略的强化学习的优缺点
- *(掌握)* 策略梯度定理、蒙特卡洛策略梯度算法 *$Q \rightarrow G_t$* (掌握) *(掌握)* (REINFORCE)、Softmax随机策略
- REINFORCE 存在的问题、Actor-Critic的思想、含义 *(掌握) 算法流程*
- A2C算法 *(引入什么函数)*



第七讲 深度强化学习价值方法

□ 深度强化学习的思想及特点

□ 深度强化学习带来的关键变化 (等阶)

□ 深度强化学习的分类 (价值、随机确定) (详细说出算法)

□ 深度Q网络 (DQN) 的思想及解决办法、算法流程 { 经验回放 双网络 (说出问题)

□ Q-learning中的过估计、Double DQN (不默认)

算法流程

□ Dueling DQN的改进措施、网络结构、优点

引入函数 对比 输出函数/值. 优点



第八讲 深度强化学习策略方法

softmax表达式

策略网络的梯度，策略梯度和Q学习的对比

异同点

A3C和A2C的改进，A3C框架图，了解A3C算法流程

算法流程讲解

策略梯度的缺点

策略梯度以期望为条件的期望

TRPO原理、 θ 更新的表达式和过程

(讲解)

约束策略更新过程讲解

TRPO的不足，PPO和TRPO的不同与改进措施

DPG：确定性策略梯度

(讲解)

(讲解)

DDPG：深度确定性策略梯度

相对于DPG的改进

算法大致流程

(讲解)



第九讲 基于模型的深度强化学习

- 基于模型的强化学习的特点 *P362*
- 模型预测控制 *P364 (掌握)*
- 打靶法 *(复述)* *(交叉熵)*
 - 算法流程、优缺点、改进方法
- PETS算法
 - PE、TS的含义 *P371 图*
 - 两种不确定性
- 分支推演 *(讲解)*
 - 含义、对策略价值误差的分析
 - MBPO算法要点



第十讲 模仿学习

- 模仿学习的特点、示例、难点
- 模仿学习与监督学习相比较
- 三类模仿学习算法 (总结)
- 行为克隆
 - 分布偏移、DAgger技术大致流程、可能面临的挑战 多模态
- 逆强化学习
 - 正逆强化学习对比、最大因果熵逆强化学习的步骤及优缺点 13 解算点思路
- 生成对抗模仿学习
 - GAIL和GAN
 - 判别器 D 的作用
- 生成对抗网络与逆强化学习之间的联系 (说此异同点)



第十一讲 离线强化学习

- 离线强化学习的动机、定义、优势 *P404*
- 在线策略学习、离线强化学习、离线策略学习的不同
- 外延误差问题
- 离线强化学习的分类
- BCQ
 - 基本思路、实现方法、算法大致流程 *(解题思想)*
- CQL
 - 思路、目标函数的三部分构成、正则项



第十二讲 参数化行动空间

- 离散和连续行动空间对比
- 参数化的动作空间
 - 含义、举例 (游戏辅助)
- 参数化动作马尔可夫决策过程、强化学习方法分类
- 处理离散-连续混合动作空间的算法途径
- 离散化连续动作空间
 - 表示方法、适用算法、缺点
- 放宽离散动作空间，如何选择离散动作？适用算法（DDPG模型）
- Q-PAMDP算法特点、大致流程
- 参数化深度Q网络（PDQN） (1版)
 - 思路、与DDPG的对比

离散化
连续化
参数化



第十三讲 目标导向的强化学习

□ 适用的强化学习范围特点

□ 目标导向的强化学习

- 思路、含义

□ 目标导向的强化学习的问题建模

- 符号约定、与一般强化学习的不同、智能体目标

(符号约定)

□ 具体模块定义

- 目标导向的奖励函数
- 目标导向的策略
- 普适价值函数逼近

□ 经典GoRL算法：HER

- 做法、大致算法流程

(讲解思路)



第十四讲 多智能体强化学习

- 多智能体强化学习的特点 *举例说明*
- 举例 *←*
- 多智能体学习的难点 *难点*
- 在博弈论视角下，序贯决策的三种问题
- 随机博弈的问题建模
 - 博弈表格、状态转移、奖励函数、价值函数
- 多智能体强化学习的方法分类
- 完全中心化方法：整体智能体的特点和缺点、纳什Q学习的操作步骤及缺点
- 完全去中心化方法：优缺点、独立Q学习与独立PPO *思路 P482 图*
- 中心化训练去中心化执行 (CTDE)：含义、问题建模、MADDPG特点及流程

