

# 《强化学习》复习题汇总

基于课件汇总（共485页）整理，涵盖全部14讲考点  
中国矿业大学（北京）人工智能系 · 孙俊忍老师课程

## 第一讲 强化学习简介

### 核心概念

#### 1. 决策和预测有什么不同？请举例说明。

决策直接改变世界（环境），并需要承担后果（如医生直接给病人下达治疗方案）；预测仅产生信号，不改变环境（如AI告诉医生病人的患病概率，最终由医生决策）。决策改变了未来的发展路径，预测只是辅助别人改变世界。

#### 2. 强化学习的定义是什么？

通过从交互中学习来实现目标的计算方法。智能体在某种程度上感知环境的状态，采取行动影响状态，并以随时间推移最大化累积奖励为目标。

#### 3. 强化学习系统的四大要素是什么？

- **历史 (History)**：观察、行动和奖励的序列  $H_t = O_1, R_1, A_1, \dots, O_t, R_t$
- **状态 (State)**：用于确定接下来会发生的事情的信息，是历史的函数  $S_t = f(H_t)$
- **策略 (Policy)**：从状态到行动的映射，分为确定性策略  $a = \pi(s)$  和随机策略  $\pi(a|s) = P[A_t = a|S_t = s]$
- **价值函数 (Value Function)**：对未来累积奖励的预测  $Q^\pi(s, a) = \mathbb{E}_\pi[R_{t+1} + \gamma Q^\pi(s', a') | S_t = s, A_t = a]$
- （另加：**模型 Model**，用于模拟环境行为）

#### 4. 强化学习的方法分类有哪些？

- **基于价值 (Value-based)**：知道什么是好的，有价值函数，无显式策略
- **基于策略 (Policy-based)**：知道怎么行动，有策略，无价值函数
- **Actor-Critic**：同时学习策略和价值函数

#### 5. 深度强化学习带来的关键变化有哪些？

将深度神经网络用于价值函数和策略近似，实现端到端学习，但带来了新挑战：高维参数空间、训练不稳定、容易过拟合、需要大量数据和高性能计算（CPU采集经验 + GPU训练网络的平

衡)。

## 6. 深度强化学习的研究前沿有哪些？

- 基于模拟模型的强化学习 (Model-based RL)
- 目标策动的层次化强化学习 (Goal-oriented RL)
- 模仿学习 (Imitation Learning)
- 多智能体强化学习 (Multi-agent RL)

## 7. 强化学习的落地场景有哪些？

无人驾驶、游戏AI、交通灯调度、网约车派单、组合优化、推荐搜索系统、数据中心节能优化、对话系统、机器人控制、路由选路、工业互联网等。

## 8. 什么是利用与探索的均衡 (Exploration vs. Exploitation) ?

- 利用 (Exploitation): 执行能获得已知最优收益的决策
- 探索 (Exploration): 尝试更多可能的决策, 不一定最优, 但可能发现更好的策略
- 二者需要平衡, 一直利用会陷入局部最优, 一直探索则total regret线性增长

# 多臂老虎机

## 9. 多臂老虎机的问题模型是什么？

- 动作集合:  $a_i \in \mathcal{A}, i = 1, \dots, K$
- 收益函数分布:  $\mathcal{R}(r|a_i) = \mathbb{P}(r|a_i)$
- 目标: 最大化累积收益  $\max \sum_{t=1}^T r_t$ , 其中  $r_t \sim \mathcal{R}(\cdot|a_t)$

## 10. 多臂老虎机的算法流程是什么？

1. 初始化:  $Q(a_i) := c_i, N(a_i) = 0$
2. 主循环  $t = 1 : T$ :
  - 利用策略  $\pi$  选取动作  $a$
  - 获取收益  $r_t = \text{Bandit}(a)$
  - 更新计数器:  $N(a) := N(a) + 1$
  - 更新估值:  $Q(a) := Q(a) + \frac{1}{N(a)}(r_t - Q(a))$

## 11. Regret函数是什么？

- 最优收益:  $Q^* = \max_{a_i \in \mathcal{A}} Q(a_i)$
- 单步Regret:  $R(a_i) = Q^* - Q(a_i)$
- Total Regret:  $\sigma_R = \mathbb{E}_{a \sim \pi} \sum_{t=1}^T R(a_t^i)$
- 目标:  $\min \sigma_R \Leftrightarrow \max \mathbb{E}_{a \sim \pi} \sum_{t=1}^T Q(a_t^i)$

12. 贪心策略 vs.  $\epsilon$ -greedy策略的比较？

|              | 贪心策略                                           | $\epsilon$ -greedy策略                    |
|--------------|------------------------------------------------|-----------------------------------------|
| 动作选择         | $a^* = \arg \max Q(a_i)$                       | 以 $1 - \epsilon$ 概率贪心，以 $\epsilon$ 概率随机 |
| Total Regret | 线性增长 $\sigma_R \propto T \cdot (Q(a_i) - Q^*)$ | 线性增长，但增长率更小                             |
| 缺点           | 无探索，陷入局部最优                                     | 常量 $\epsilon$ 仍导致线性增长                   |

13. 什么是乐观初始化（Optimistic Initialization）？

给  $Q(a_i)$  一个较高的初始化值，增量式更新  $Q(a_i) := Q(a_i) + \frac{1}{N(a_i)} (r_t - Q(a_i))$ 。有偏估计，但随着采样增加偏差影响减小，仍可能陷入局部最优。

14. 什么是UCB上置信界法（Upper Confidence Bounds）？

$$a = \arg \max_{a \in \mathcal{A}} \hat{Q}(a) + \hat{U}(a)$$

其中  $\hat{U}(a) = \sqrt{-\frac{\log p}{2N_i(a)}}$ ， $N(a)$  越大， $U(a)$  越小（不确定性减小）。收敛性：  
 $\lim_{t \rightarrow \infty} \sigma_R \leq 8 \log t \sum_{a|\Delta_a > 0} \Delta_a$ （对数渐近收敛）。

15. Thompson Sampling方法是什么？

根据每个动作成为最优的概率来选择动作。实现：根据当前每个动作  $a$  的预测价值概率分布  $p(Q(a))$  来采样到其价值  $Q(a)$ ，选择价值最大的动作。实验效果接近理论渐近最优下界。

---

## 第二讲 马尔可夫决策过程

16. 随机过程和马尔可夫过程有什么不同？

随机过程研究动态随机现象随时间演变的规律，状态转移依赖历史  $\mathbb{P}[S_{t+1}|S_1, \dots, S_t]$ ；马尔可夫过程满足**马尔可夫性质**："The future is independent of the past given the present"，即  $\mathbb{P}[S_{t+1}|S_t] = \mathbb{P}[S_{t+1}|S_1, \dots, S_t]$ ，当前状态是未来的充分统计量。

17. MDP五元组是什么？

$(S, A, P_{sa}, \gamma, R)$ ：

- $S$ ：状态集合
- $A$ ：动作集合
- $P_{sa}$ ：状态转移概率  $P_{sa} : S \times A \mapsto \Omega(s)$
- $\gamma \in [0, 1]$ ：折扣因子

- $R : S \times A \mapsto \mathbb{R}$ : 奖励函数

## 18. 累计奖励表达式是什么？

$$R(s_0, a_0) + \gamma R(s_1, a_1) + \gamma^2 R(s_2, a_2) + \dots$$

折扣因子  $\gamma$  使智能体更重视即时奖励 ("今天的\$1比明天的\$1更有价值")。

## 19. 目标、策略和价值函数的定义？

- **目标**: 选择能最大化累积奖励期望的动作  $\mathbb{E}[R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots]$
- **策略**:  $\pi(s) : S \rightarrow A$ , 在状态  $s$  下采取动作  $a = \pi(s)$
- **价值函数**:  $V^\pi(s) = \mathbb{E}[R(s_0) + \gamma R(s_1) + \dots | s_0 = s, \pi]$

## 20. 价值函数的Bellman等式是什么？

$$V^\pi(s) = R(s) + \gamma \sum_{s' \in S} P_{s\pi(s)}(s') V^\pi(s')$$

最优价值函数:  $V^*(s) = R(s) + \max_{a \in A} \gamma \sum_{s' \in S} P_{sa}(s') V^*(s')$

最优策略:  $\pi^*(s) = \arg \max_{a \in A} \sum_{s' \in S} P_{sa}(s') V^*(s')$

## 21. 价值迭代的过程是什么？

1. 对每个状态  $s$ , 初始化  $V(s) = 0$
2. 重复直到收敛: 对每个状态更新  $V(s) = R(s) + \max_{a \in A} \gamma \sum_{s' \in S} P_{sa}(s') V(s')$

注: 过程中没有明确的策略, 初始化价值而非策略。

## 22. 策略迭代的过程是什么？

1. 随机初始化策略  $\pi$
2. 重复直到收敛:
  - a) 令  $V := V^\pi$  (策略评估)
  - b) 对每个状态更新  $\pi(s) = \arg \max_{a \in A} \sum_{s' \in S} P_{sa}(s') V(s')$  (策略改进)

## 23. 价值迭代和策略迭代的对比？

|      | 价值迭代            | 策略迭代                  |
|------|-----------------|-----------------------|
| 初始化  | 价值函数 $V(s) = 0$ | 随机策略 $\pi$            |
| 更新方式 | 贪心更新            | Bellman等式更新价值函数 (代价大) |
| 收敛速度 | 较慢 (空间大时更实用)    | 较快 (空间小时)             |
| 适用场景 | 大状态空间, 无状态转移循环  | 小状态空间                 |

## 24. 同步和异步迭代有什么区别？

- **同步迭代**：存储两份价值函数拷贝，用  $V_{old}$  计算  $V_{new}$ ，再更新
- **异步迭代**：只存储一份，直接原地更新

## 25. 学习模型 & 优化策略的算法流程？

1. 随机初始化策略  $\pi$
  2. 重复直到收敛：
    - a) 在MDP中执行  $\pi$ ，收集经验数据
    - b) 使用累积经验更新对  $P_{sa}$  和  $R$  的估计
    - c) 执行价值迭代，得到新的估计价值函数  $V$
    - d) 根据  $V$  更新策略  $\pi$  为贪心策略
- 

# 第三讲 值函数估计

## 26. 无模型强化学习的含义是什么？

在现实问题中，状态转移和奖励函数通常未给出，只能观察到片段(episodes)。无模型强化学习直接从经验中学习值 (value) 和策略 (policy)，无需构建MDP模型。关键步骤：(1) 估计值函数；(2) 优化策略。

## 27. 动态规划如何计算值函数？

已知MDP时，通过Bellman等式迭代更新： $V^\pi(s) = R(s) + \gamma \sum_{s' \in S} P_{s\pi(s)}(s')V^\pi(s')$

## 28. 蒙特卡洛方法的定义及举例？

依赖于重复随机抽样获得数值结果。在强化学习中，用于估计值函数的均值替代期望：

$V(s) \approx \frac{1}{N} \sum_{i=1}^N G_t^{(i)}$ 。例如：围棋胜率估计 = (以当前状态为起点模拟的胜利次数) / (总模拟次数)。

## 29. 蒙特卡洛价值估计的实现流程？

目标：从策略  $\pi$  下的经验片段学习  $V^\pi$ 。

- 累计奖励： $G_t = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-1} R_T$
- 增量更新：对片段中每个时间步状态  $S_t$ ：
  - $N(S_t) \leftarrow N(S_t) + 1$
  - $V(S_t) \leftarrow V(S_t) + \frac{1}{N(S_t)}(G_t - V(S_t))$
- 非稳态问题使用固定步长： $V(S_t) \leftarrow V(S_t) + \alpha(G_t - V(S_t))$

30. 使用重要性采样的离线策略蒙特卡洛是什么？

用策略  $\mu$  产生的数据评估策略  $\pi$ 。对累积奖励按重要性比率加权：

$$G_t^{\pi/\mu} = \frac{\pi(a_t|s_t)}{\mu(a_t|s_t)} \cdot \frac{\pi(a_{t+1}|s_{t+1})}{\mu(a_{t+1}|s_{t+1})} \cdots G_t$$

更新： $V(s_t) \leftarrow V(s_t) + \alpha(G_t^{\pi/\mu} - V(s_t))$ 。缺点：显著增大方差。

31. 使用重要性采样的离线策略时序差分是什么？

只需一步重要性采样修正：

$$V(s_t) \leftarrow V(s_t) + \alpha \frac{\pi(a_t|s_t)}{\mu(a_t|s_t)} (r_{t+1} + \gamma V(s_{t+1}) - V(s_t))$$

比蒙特卡洛重要性采样方差更低，策略只需在单步中被近似。

32. 时序差分学习（TD）的特点是什么？

$$V(S_t) \leftarrow V(S_t) + \alpha(R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$$

- 时序差分目标： $R_{t+1} + \gamma V(S_{t+1})$
- 时序差分误差： $\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$
- 直接从经验片段学习，**模型无关**
- 通过**自举法（bootstrapping）**，从不完整片段中学习

33. MC和TD的对比（优缺点）？

| 特点       | 蒙特卡洛（MC）     | 时序差分（TD）     |
|----------|--------------|--------------|
| 是否需要完整片段 | 是，必须等到终止     | 否，每步可更新      |
| 有偏/无偏    | 无偏估计         | 有偏估计（用估计值更新） |
| 方差       | 高（多步随机）      | 低（单步随机）      |
| 收敛性      | 收敛性好，函数近似也如此 | 有时不收敛（函数近似时） |
| 初始值敏感性   | 不敏感          | 更敏感          |
| 连续环境     | 只能用于片段化任务    | 可用于连续任务      |

34. n步时序差分和n步累计奖励是什么？

n步累计奖励： $G_t^{(n)} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} + \gamma^n V(S_{t+n})$

n步TD学习： $V(S_t) \leftarrow V(S_t) + \alpha(G_t^{(n)} - V(S_t))$

当  $n = 1$  时为TD，当  $n = \infty$  时为MC。

## 第四讲 无模型控制方法

### 35. SARSA的含义和更新公式？

SARSA是在线策略（on-policy）时序差分控制方法，对每个 $(s, a, r, s', a')$ 元组更新：

$$Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma Q(s', a') - Q(s, a))$$

- 策略评估：SARSA更新Q值
- 策略改进： $\epsilon$ -greedy策略改进
- 两个"A"都由当前策略选择

### 36. Q学习的特点和更新表达式？

Q学习是离线策略（off-policy）方法：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left( r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right)$$

特点：无需重要性采样（直接学习 $Q(s, a)$ ，相当于 $\mu$ 没有起作用）。收敛定理：Q学习控制收敛到最优状态-动作值函数  $Q(s, a) \rightarrow Q^*(s, a)$ 。

### 37. $Q(s_t, a_t)$ 值更新表达式的含义？

$r_{t+1}$ ：即时奖励； $\gamma \max_{a'} Q(s_{t+1}, a')$ ：下一状态的最优价值估计（折扣后）；两者之和为TD目标，减去当前估计后乘以步长  $\alpha$  进行更新。

### 38. 离线策略学习的含义及为什么使用？

目标策略  $\pi(a|s)$  用于价值函数评估，行为策略  $\mu(a|s)$  用于收集数据。使用原因：平衡探索与利用、从人类/其他智能体观察学习、重用旧策略产生的经验。

### 39. 了解Q学习收敛性证明的思路？

定义收缩算子  $H$ ：  $HQ = r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot|s, a)} [\max_{a'} Q(s', a')]$ 。最优值函数  $Q^*$  是  $H$  的不动点（ $Q^* = HQ^*$ ）。通过柯西数列论证任何初始  $Q$  函数最终收敛到  $Q^*$ 。

### 40. TD( $\lambda$ )算法中的 $\lambda$ -累计奖励是什么？

$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} G_t^{(n)}$$

- $\lambda = 0$ ：等价于单步TD
- $\lambda = 1$ ：等价于蒙特卡洛
- 使用权重  $(1 - \lambda)\lambda^{n-1}$  对所有 $n$ 步累计奖励加权平均

## 第五讲 规划与学习

### 41. 策略值函数估计、策略提升含义？

- **策略评估**：给定MDP和策略  $\pi$ ，计算  $V^\pi(s) = \mathbb{E}_{a \sim \pi(s)}[Q^\pi(s, a)]$
- **策略提升**：若对任何状态  $s$  有  $Q^\pi(s, \pi'(s)) \geq V^\pi(s)$ ，则  $\pi'$  是  $\pi$  的策略提升

**策略提升定理**：若  $\pi'$  满足上述条件，则对任何状态  $s$  有  $V^{\pi'}(s) \geq V^\pi(s)$ ，即  $\pi'$  比  $\pi$  更优。

### 42. 模型的含义、分类及作用？

- **含义**：给定状态和动作，预测下一个状态和奖励的分布  $p(s', r|s, a)$
- **分类**：分布模型（描述所有可能性及概率）、样本模型（只产生一条轨迹）
- **作用**：产生模拟的经验数据  $\{s, a, r, s'\}$

### 43. 规划的含义、通用框架、举例及优势？

- **含义**：输入模型，输出策略的搜索过程
- **框架**：通过模型采样得到模拟数据  $\rightarrow$  利用模拟数据更新值函数  $\rightarrow$  改进策略
- **举例**：动态规划（搜索整个状态空间）
- **优势**：可在任何时间被打断或重定向；小而增量式的时间步规划在复杂问题中有效

### 44. 规划和学习有什么不同？

- **不同点**：规划用模型产生的模拟经验；学习用环境产生的真实经验
- **相同点**：都通过回溯（back-up）更新值函数估计；学习的方法可用在模拟经验上

### 45. Dyna算法的经验不同用途、框架？

经验的两种用途：（1）**更新模型**（间接强化学习，需求数据少）；（2）**更新值函数和策略**（直接强化学习，简单不受模型偏差影响）。

框架：

- 与环境交互  $\rightarrow$  直接RL更新值函数和策略
- 与环境交互  $\rightarrow$  学习模型
- 基于模型随机采样模拟经验  $\rightarrow$  规划更新值函数和策略

**Dyna-Q算法流程**：在Q学习基础上，额外执行n次规划步骤（从模型中采样过去见过的  $S, A$ ，用模型预测  $R, S'$ ，执行Q学习更新）。

**Dyna-Q+的改进**：奖励改为  $r + \kappa\sqrt{\tau}$ ，其中  $\tau$  是某状态多久未被到达，鼓励探索未访问的状态动作。



46. 优先级采样的含义？

根据值改变的幅度定义优先级  $P \leftarrow |R + \gamma \max_a Q(S', a) - Q(S, A)|$ ，使具有更大更新幅度的状态动作对被优先更新，收敛更快。

47. 期望更新和采样更新对比？

|     | 期望更新    | 采样更新      |
|-----|---------|-----------|
| 需要  | 分布模型    | 采样模型      |
| 计算量 | 大       | 小         |
| 偏差  | 无偏（更准确） | 有采样误差     |
| 适用  | 小分支因子   | 大分支因子、多状态 |

48. 轨迹采样的优缺点？

- **优点：**不需要知道当前策略下状态的分布，计算量少，简单有效
- **缺点：**不断重复更新已经被访问的状态，忽略许多无关状态

49. 实时动态规划（RTDP）和决策时规划的区别？

- **RTDP：**实时轨迹采样，只更新轨迹访问的状态值，能跳过策略无关状态，满足条件时可以概率1收敛
- **决策时规划：**只着眼于当前状态的动作选择，为当前状态选一个动作（如启发式搜索、Rollout算法、蒙特卡洛树搜索）

50. 了解启发式搜索、Rollout算法、蒙特卡洛树搜索？

- **启发式搜索：**从当前状态展开树结构，叶节点代表估计值函数，回溯到当前状态，看多步规划下的最优行动
- **Rollout算法：**从当前状态进行蒙特卡洛估计，选取最高估计值动作，在下一状态重复（时间复杂度  $O(K \cdot A \cdot T_{eval})$ ）
- **MCTS：**选择→扩展→模拟（rollout）→回溯，保留部分经验，应用于AlphaGo

---

## 第六讲 价值和策略近似逼近方法

51. 离散化连续马尔可夫决策过程，分桶的含义及优缺点？

对连续状态空间使用网格切分或分桶（将相似状态归类），得到离散  $\hat{S}$ ，转化为  $(\hat{S}, A, P_{\hat{s}a}, \gamma, R)$ 。

- **优点：**操作简洁直观、高效
- **缺点：**过于简单，可能假设每个离散区间常数值；**维度灾难**  $|S| = R^n \Rightarrow |\hat{S}| = \{1, \dots, k\}^n$

## 52. 值函数近似的主要形式？

$V_\theta(s) \approx V^\pi(s)$ ,  $Q_\theta(s, a) \approx Q^\pi(s, a)$ , 其中  $\theta$  可通过强化学习更新。可用线性模型、神经网络等可微函数（因为需要做梯度优化）。

## 53. 随机梯度下降（SGD）的值函数近似？

目标：最小化  $J(\theta) = \mathbb{E}_\pi[\frac{1}{2}(V^\pi(s) - V_\theta(s))^2]$

$$\theta \leftarrow \theta + \alpha(V^\pi(s) - V_\theta(s)) \frac{\partial V_\theta(s)}{\partial \theta}$$

## 54. 蒙特卡洛状态值函数近似？

用累积奖励  $G_t$  作为真实目标值，在"训练数据"  $(s_1, G_1), (s_2, G_2), \dots$  上做监督学习：

$$\theta \leftarrow \theta + \alpha(G_t - V_\theta(s)) \frac{\partial V_\theta(s)}{\partial \theta}$$

## 55. 时序差分的状态-动作值函数近似？

$$\theta \leftarrow \theta + \alpha(r_{t+1} + \gamma Q_\theta(s_{t+1}, a_{t+1}) - Q_\theta(s, a)) \frac{\partial Q_\theta(s, a)}{\partial \theta}$$

注意：虽然  $\theta$  出现在目标中，但不计算目标函数的梯度（半梯度方法）。

## 56. 参数化策略的含义？

将策略参数化： $\pi_\theta(a|s) = P(a|s; \theta)$ ，策略可以是确定性的  $a = \pi_\theta(s)$  或随机的。将可见状态泛化到未知状态上。

## 57. 基于策略的强化学习的优缺点？

- **优点：**更好的收敛性；在高维度或连续动作空间更有效；能学习随机策略
- **缺点：**通常收敛到局部最优；策略评估不够高效且方差大

## 58. 策略梯度定理？

对任意可微策略  $\pi_\theta(a|s)$  和策略目标函数  $J$ （包括起始状态、平均奖励、平均价值等目标）：

$$\frac{\partial J(\theta)}{\partial \theta} = \mathbb{E}_{\pi_\theta} \left[ \frac{\partial \log \pi_\theta(a|s)}{\partial \theta} Q^{\pi_\theta}(s, a) \right]$$

## 59. 蒙特卡洛策略梯度算法（REINFORCE）？

利用累积奖励  $G_t$  作为  $Q^{\pi_\theta}(s, a)$  的无偏采样，更新：

$$\Delta\theta_t = \alpha \frac{\partial \log \pi_\theta(a_t|s_t)}{\partial \theta} G_t$$

## 60. Softmax随机策略？

$$\pi_\theta(a|s) = \frac{e^{f_\theta(s,a)}}{\sum_{a'} e^{f_\theta(s,a')}}$$

其log形式梯度： $\frac{\partial \log \pi_\theta(a|s)}{\partial \theta} = \frac{\partial f_\theta(s,a)}{\partial \theta} - \mathbb{E}_{a' \sim \pi_\theta(a'|s)} \left[ \frac{\partial f_\theta(s,a')}{\partial \theta} \right]$

## 61. REINFORCE存在的问题、Actor-Critic的思想？

REINFORCE的问题：基于片段式数据（需要终止状态）、低数据利用效率、高训练方差（最重要缺陷）。

Actor-Critic思想：为什么不建立一个可训练的值函数  $Q_\Phi$  来估计  $G_t$ ？

- **演员（Actor）**  $\pi_\theta(a|s)$ ：采取动作使评论家满意的策略
- **评论家（Critic）**  $Q_\Phi(s,a)$ ：学习准确估计演员策略动作价值的值函数

## 62. A2C算法？

优势函数： $A^\pi(s,a) = Q^\pi(s,a) - V^\pi(s)$

由于  $Q^\pi(s,a) \approx r(s,a) + \gamma V^\pi(s')$ ，所以  $A^\pi(s,a) \approx r(s,a) + \gamma V^\pi(s') - V^\pi(s)$ ，只需拟合  $V$  函数即可。减去基线降低方差，同时提供更多信息（降低较差动作概率，提高较优动作概率）。

# 第七讲 深度强化学习价值方法

## 63. 深度强化学习的思想及特点？

利用深度神经网络进行价值函数和策略近似，使RL算法能以端到端方式解决复杂问题。比单独的RL和DL都更难训练（高维参数空间、训练不稳定、数据需求大）。

## 64. 深度强化学习的分类？

- **基于价值的方法**：深度Q网络（DQN）及其扩展
- **基于随机策略的方法**：策略梯度、TRPO、PPO、A3C
- **基于确定性策略的方法**：DPG、DDPG

## 65. 深度Q网络（DQN）的思想及解决办法、算法流程？

**思想**：使用神经网络逼近  $Q_\theta(s,a)$ ，但直接使用不稳定。

**解决办法**：

1. **经验回放**：存储  $e_t = (s_t, a_t, s_{t+1}, r_t)$  于数据库  $D$  中，采样时服从均匀分布（打破数据相关性）
2. **目标网络**  $Q_{\theta^-}$ ：使用较旧参数，每隔  $C$  步与训练网络同步（稳定目标值）

**算法流程：**

1. 收集数据：用 $\epsilon$ -greedy探索，将  $(s_t, a_t, s_{t+1}, r_t)$  放入经验池
2. 采样：从数据库中采样  $k$  个样本
3. 更新网络：计算Loss，更新  $Q$  网络参数  $\theta$ ；每  $C$  次迭代更新目标网络  $\theta^-$

损失函数：
$$L_i(\theta_i) = \mathbb{E}_{s,a,r,s' \sim U(D)} \left[ \left( r + \gamma \max_{a'} Q(s', a'; \theta_i^-) - Q(s, a; \theta_i) \right)^2 \right]$$

**66. Q-learning中的过估计、Double DQN?**

**过估计原因：** $\mathbb{E}[\max(X_1, X_2)] \geq \max(\mathbb{E}[X_1], \mathbb{E}[X_2])$ ，max操作使Q值越来越大甚至超过真实值，且动作数越多越严重。

**Double DQN：**解耦合动作选择和价值估计，用不同网络分别负责：

$$y_t = r_t + \gamma Q_{\theta'}(s_{t+1}, \arg \max_{a'} Q_{\theta}(s_{t+1}, a'))$$

（行为网络  $\theta$  选择动作，目标网络  $\theta'$  评估价值）

**67. Dueling DQN的改进措施、网络结构、优点?**

**核心思想：** $Q(s, a) = V(s) + A(s, a)$ ，其中  $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$  是优势函数。

**网络结构：**共享卷积层  $\rightarrow$  分为两支（ $V(s; \theta, \beta)$  和  $A(s, a; \theta, \alpha)$ ）  $\rightarrow$  聚合：

$$Q(s, a; \theta, \alpha, \beta) = V(s; \theta, \beta) + \left( A(s, a; \theta, \alpha) - \frac{1}{|A|} \sum_{a'} A(s, a'; \theta, \alpha) \right)$$

**优点：**可在不考虑动作的情况下判断状态好坏；状态值函数学习更有效（一个  $V$  对应多个  $A$ ）。

**第八讲 深度强化学习策略方法**

**68. 策略网络的梯度，策略梯度和Q学习的对比?**

|      | Q学习                | 策略梯度             |
|------|--------------------|------------------|
| 学习对象 | $Q_{\theta}(s, a)$ | $\pi_{\theta}(a$ |
| 优化目标 | 最小化TD误差            | 直接最大化策略价值        |
| 更新方向 | 梯度下降               | 梯度上升             |

|      | Q学习                                                                                   | 策略梯度                                                                 |
|------|---------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| 目标函数 | $\min J(\theta) = \mathbb{E}[(r + \gamma \max_{\theta'} Q_{\theta'} - Q_{\theta})^2]$ | $\max J(\theta) = \mathbb{E}_{\pi_{\theta}}[A^{\pi_{\theta}}(s, a)]$ |

## 69. A3C和A2C的改进、A3C框架图？

A3C = 异步 (Asynchronous) + 优势 (Advantage) + 动作评价 (Actor-Critic)。

**改进：**异步并行执行多个环境，多个worker独立与各自环境交互，梯度异步更新全局网络，有效利用多核CPU资源。

优势函数： $A(s_t, a_t; \theta_v) = \sum_{i=0}^{k-1} \gamma^i r_{t+i} + \gamma^k V(s_{t+k}; \theta_v) - V(s_t; \theta_v)$

## 70. 策略梯度的缺点？

步长难以确定：采集到的数据分布随策略更新而变化，步长太大时会导致更新后策略变差，进而新采集数据变坏，形成恶性循环。

## 71. TRPO原理、 $\theta$ 更新的表达式和过程？

使用KL散度约束策略更新的幅度：

$$\theta' \leftarrow \arg \max_{\theta'} \sum_t \mathbb{E}_{s_t \sim p_{\theta}, a_t \sim \pi_{\theta}} \left[ \frac{\pi_{\theta'}(a_t | s_t)}{\pi_{\theta}(a_t | s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t) \right]$$

$$\text{such that } \mathbb{E}_{s_t \sim p} [D_{KL}(\pi_{\theta'}(a_t | s_t) || \pi_{\theta}(a_t | s_t))] \leq \epsilon$$

步骤：(1) 优化上式更新  $\theta'$ ；(2) 更新  $\lambda \leftarrow \lambda + \alpha(D_{KL} - \epsilon)$ 。需要共轭梯度法求解。

## 72. TRPO的不足，PPO和TRPO的不同与改进措施？

**TRPO不足：**近似带来误差、求解约束优化问题困难。

**PPO改进：**

1. **截断式优化目标：** $L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)]$ ，构建优化目标下界，避免步子过大
2. **优势函数用多步TD：** $\hat{A}_t = -V(s_t) + r_t + \gamma r_{t+1} + \dots + \gamma^{T-t} V(s_T)$
3. **自适应KL惩罚项：**动态调整  $\beta$

PPO更简洁、更简单、实验效果更好，是目前最常用的深度策略梯度算法。

## 73. DPG（确定性策略梯度）？

对于连续动作，确定性策略  $a = \pi_{\theta}(s)$  可微，梯度为：

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{s \sim \rho^{\pi}} [\nabla_{\theta} \pi_{\theta}(s) \nabla_a Q^w(s, a)|_{a=\pi_{\theta}(s)}]$$

## 74. DDPG（深度确定性策略梯度）相对于DPG的改进及算法流程？

**改进：**在DPG基础上加入：（1）经验重放（离线策略）；（2）目标网络；（3）在动作输入前批标准化Q网络；（4）添加连续噪声用于探索。

**算法流程：**收集数据（带噪声动作）→ 存入经验池 → 采样 → 更新Critic（Q网络）→ 更新Actor（策略网络）→ 延迟更新目标网络。

---

# 第九讲 基于模型的深度强化学习

## 75. 基于模型的强化学习的特点？

使用环境模型（模拟器）替代真实环境，从模型中采样模拟数据  $\{(s, a, r, s')\}$  训练智能体策略，提升样本效率。模型包括：状态转移动态  $\hat{p}(s'|s, a)$  和奖励函数  $\hat{r}(s, a)$ 。

## 76. 模型预测控制（MPC）？

在每个时间步，算法采样多条轨迹，从这些轨迹中得到经验最优轨迹，取该轨迹的第一个动作来执行，如此往复。不需要学习值函数和策略，直接基于模型工作。

## 77. 打靶法的算法流程、优缺点、改进方法？

**流程：**从  $s_0$  出发，对每个候选  $a_0$  附上随机动作序列  $[a_0, a_1, \dots, a_T]$ ，用模型交互得到轨迹，计算经验价值  $\hat{Q}(s_0, a_0) = \sum_t \gamma^t \hat{r}_t$ ，选最高价值动作执行。

**优点：**实现简单，无训练开销，不需要预先设置时间步。

**缺点：**不确定性高（方差大），可能无法选到最优动作。

**改进：**交叉熵方法（CEM）——维护带来较高奖励的动作分布，从该分布中采样。

## 78. PETS算法中PE、TS的含义及两种不确定性？

PETS = Probabilistic Ensembles with Trajectory Sampling。

- **PE（概率集成）：**用多个高斯过程神经网络构成集成，刻画两种不确定性：
  - **认知不确定性（epistemic uncertainty）：**不同单模型之间的不一致性，反映数据缺少区域的模型不确定性
  - **偶然不确定性（aleatoric uncertainty）：**每个高斯过程建模真实随机环境的固有随机性
- **TS（轨迹采样）：**每次预测从  $N$  个模型中挑选一个，一条轨迹采样使用多个环境模型

## 79. 分支推演的含义、对策略价值误差的分析、MBPO算法要点？

**分支推演 (Branched Rollout)**：从真实轨迹中随机选择状态作为起点，用环境模型和当前策略做交互，采样  $k$  步得到分支轨迹，与真实数据共同训练策略。

**策略价值误差分析**： $|\eta(\pi) - \hat{\eta}(\pi)|$  与模型泛化误差和策略偏移程度有关，随  $k$  增大：误差因策略偏移增大，但样本效率提升。当模型泛化误差/策略偏移程度比率足够小时， $k > 0$  有利。

**MBPO算法要点**：

- 分支起点从真实经验轨迹中随机采样任何状态（非必须从初始状态）
- 分支步数  $k$  取决于环境模型和策略质量
- 得到推演数据后，使用Soft AC算法训练策略

---

## 第十讲 模仿学习

### 80. 模仿学习的特点、示例、难点？

**特点**：从专家示例中学习策略，仅给出专家轨迹，奖励函数未知。

**示例**：自动驾驶、机器人控制。

**难点**：某些任务难以定义奖励函数；人为设置的奖励函数可能导致不合理行为。

### 81. 模仿学习与监督学习的比较？

模仿学习需要考虑：（1）解的结构特征（约束、动态平滑性、多步计划连贯性）；（2）决策者决策和输入分布之间的关系（在线/离线策略）；（3）数据收集成本高，需最小化。

### 82. 三类模仿学习算法？

1. **行为克隆 (Behavior Cloning)**：无需奖励函数，学习状态→动作的直接映射
2. **逆强化学习 (Inverse RL)**：找到使专家策略比其他策略更优的奖励函数
3. **生成对抗模仿学习 (GAIL)**：通过GAN方式自动学习奖励函数

### 83. 行为克隆的分布偏移、DAgger技术？

**分布偏移**：策略执行时遇到的状态分布与训练时看到的分布不匹配，错误会积累放大。

**DAgger (Dataset Aggregation)**：从稳定的控制器学习策略（有噪声），加入更多在线策略数据，迭代地将新状态下的专家标注加入训练集。

**其他挑战**：不具有马尔可夫性质的行为（依赖历史观测）、多模态行为。

### 84. 逆强化学习：正逆强化学习对比、最大因果熵IRL？

|    | 正向强化学习            | 逆强化学习      |
|----|-------------------|------------|
| 给定 | 状态、动作、奖励函数        | 状态、动作、专家轨迹 |
| 学习 | 最优策略 $\pi^*(a s)$ |            |

### 最大因果熵IRL步骤：

1. 找到使专家策略产生较低代价、其他策略产生较高代价的代价函数  $\hat{c}$
2. 通过使用代价函数  $\hat{c}$  进行正向RL，恢复专家策略

**优势：**使用神经网络计算成本函数。**局限性：**仍需反复求解MDP，假设环境已知。

### 85. 生成对抗模仿学习（GAIL）：与GAN的关系，判别器D的作用？

$$\min_{\pi} \max_D \mathbb{E}_{(s,a) \sim \pi_E} [\log D(s,a)] + \mathbb{E}_{(s,a) \sim \pi} [\log(1 - D(s,a))] - \lambda H(\pi)$$

判别器  $D$  的作用：判别数据是由当前策略  $\pi$ （生成器）还是专家  $\pi_E$ （真实数据）产生的，为策略提供奖励信号。

### 86. 生成对抗网络与逆强化学习之间的联系？

两者结构相似：GAN = 生成器（欺骗判别器）+ 判别器（区分真假）；IRL = 代价函数学习 + 基于代价函数的策略优化。GAIL将两者统一，判别器充当奖励函数，策略充当生成器。

## 第十一讲 离线强化学习

### 87. 离线强化学习的动机、定义、优势？

**动机：**真实环境从零训练风险高（无人驾驶、医疗）且昂贵（机器人控制）。

**定义：**在给定的离线数据集上直接训练智能体策略，训练过程中不得与环境交互。

**优势：**预训练强化学习策略；评测策略好坏；缩小学术研究与真实落地的差距；使RL更像有监督学习。

### 88. 在线策略学习、离线强化学习、离线策略学习的不同？

|            | 在线策略 | 离线策略 | 离线强化学习 |
|------------|------|------|--------|
| 训练时与环境交互   | 是    | 是    | 否      |
| 数据是否来自别的策略 | 否    | 是    | 是      |



89. 外延误差（Extrapolation Error）问题？

定义：智能体如果涉足到了从没有见过的、远离数据集的状态动作对（OOD问题），Q值估计会出现严重误差，并随TD公式传播到非OOD数据上。

根本原因：数据集分布（收集策略  $\mu$  的占用度量）和当前策略（ $\pi$  的占用度量）不一致。

90. 离线强化学习的分类？

- 无模型方法：显式限制（BCQ、BEAR、BRAC、CQL）、隐式限制（AWR、REM）
- 基于模型的方法：使用学习的模型估计不确定性（MOREl、MOPO、COMBO）

91. BCQ算法的基本思路、实现方法、算法大致流程？

基本思路：仅使用在数据集支撑上的目标Q值做时序差分计算，避免OOD动作。

实现方法：使用变分自动编码器（VAE）生成距离数据集较近的状态动作对，加上  $[-\Phi, +\Phi]$  的小扰动。

关键权衡： $n$ （采样数）和  $\Phi$ （扰动幅度）越小越接近模仿学习，越大越接近强化学习但易出OOD问题。

92. CQL算法的思路、目标函数的三部分构成、正则项？

思路：学习一个保守的、可作为价值下界的Q函数，避免在OOD数据上的过高估计。

目标函数三部分：

1. 新策略  $\mu$  的数据Q价值惩罚（降低OOD Q值）
2. 数据集支撑范围内的Q价值奖励（提升数据内Q值）
3. 时序差分误差（标准RL目标）

正则项：使用  $\mu$  和均匀分布之间的KL散度作为正则项（经验性实现）。

---

第十二讲 参数化行动空间

93. 离散和连续行动空间对比？

|      | 离散动作空间                           | 连续动作空间                       |
|------|----------------------------------|------------------------------|
| 表示   | $a \in \{a_1, a_2, \dots, a_k\}$ | $a = (x_1, x_2, \dots, x_d)$ |
| 问题类型 | 分类问题                             | 回归问题                         |
| 局限   | 无法对选择的动作微调                       | 无法考虑动作种类差异                   |

|      | 离散动作空间   | 连续动作空间    |
|------|----------|-----------|
| 适用算法 | DQN, A3C | DPG, DDPG |

#### 94. 参数化动作空间的含义、举例？

每个离散动作都被赋予连续参数：{冲刺(方向,速度), 转向(方向), 踢球(方向,力度), 停止}。混合动作空间，智能体同时决定执行何种离散动作及连续参数。

#### 95. 参数化动作马尔可夫决策过程（PAMDPs）？

混合动作空间表示： $A = \{(k, x_k) | x_k \in X_k \text{ for all } k \in \{1 \dots K\}\}$ 。强化学习方法分类：离散化连续动作、放宽离散动作空间、分开处理离散和连续动作。

#### 96. 处理离散-连续混合动作空间的算法途径？

1. **离散化连续动作空间**：表示为  $A = \{(k, x_k) | x_k \in X_k\}$ ，用DQN/A3C训练，缺点是丢失自然结构，维度爆炸
2. **放宽离散动作空间**：输出  $(f_1, \dots, f_K, x_1, \dots, x_K)$ ，用DDPG训练连续策略
3. **分开处理**：如Q-PAMDP、PDQN

#### 97. 离散化连续动作空间的表示方法、适用算法、缺点？

用离散子集近似每个  $X_k$ ，使用DQN或A3C。缺点：丢失自然结构；良好近似需要大量离散动作；维度灾难。

#### 98. 放宽离散动作空间，如何选择离散动作？适用算法（DDPG模型）？

策略输出  $(f_1, \dots, f_K, x_1, \dots, x_K)$ ，离散动作选择：确定性地取  $\arg \max_i (f_i)$  或随机地按  $\text{softmax}(f_i)$ 。Q值网络（Critic）平滑处理离散的argmax操作。

#### 99. Q-PAMDP算法特点、大致流程？

交替学习：固定  $\theta$ （参数策略），用Q学习优化离散策略  $\pi_w^d$ ；固定  $w$ （离散策略），用策略搜索优化参数策略  $\pi_\theta^a$ ；循环直至收敛。

#### 100. 参数化深度Q网络（PDQN）的思路、与DDPG的对比？

思路：DQN（选离散动作）+ DDPG（确定连续参数）的结合。

损失函数：Critic损失  $\ell_t^Q(w) = \frac{1}{2}(Q(s_t, k_t, x_{k_t}; w) - y_t)^2$ ；Actor损失  $\ell_t^\theta(\theta) = -\sum_{k=1}^K Q(s_t, k, x_k(s_t; \theta); w_t)$

## 第十三讲 目标导向的强化学习

### 101. 适用的强化学习范围特点？

大部分RL方法只能完成特定任务（固定地图、起点、终点）。适用于需要完成不同目标（起点/终点组合）的复杂任务，以及可分解成多个子任务的层次化任务。

### 102. 目标导向强化学习（GoRL）的思路、含义？

将每次任务的目标显式加入智能体的输入和奖励信号。GoRL在MDP环境中额外定义一个目标  $g$ ，显式告诉智能体，在训练过程中使用目标信息，使得测试阶段给定新目标时智能体能直接泛化。

### 103. 目标导向强化学习的问题建模（符号约定、与一般RL的不同、智能体目标）？

扩展元组： $(S, A, p, \gamma, r_g, G, \phi)$ ，其中  $G$  是目标集合， $\phi: S \rightarrow G$  将状态映射为目标， $r_g: S \times A \times G \rightarrow \mathbb{R}$  是目标导向奖励函数， $\pi_i: S \times G \rightarrow \Omega(A_i)$  是目标导向策略。

**与一般RL的不同：**策略和奖励函数都加入了目标信息。

**智能体目标：**最大化期望累积奖励  $J(\pi) = \mathbb{E}[\sum_t \gamma^t r_g(s_t, a_t, s_{t+1})]$

### 104. 具体模块定义（目标导向奖励函数、策略、普适价值函数逼近）？

- **目标导向奖励函数：**通常为  $r_g(s, a) = \mathbb{1}[\phi(s) = g]$ （一个较小阈值内达到目标为1，否则为0）
- **目标导向策略：** $\pi(a|s, g)$ ，简单实现可以拼接  $s$  和  $g$  作为输入
- **普适价值函数逼近（UVFA）：** $V: S \times G \rightarrow \mathbb{R}$ ，最简单在MLP输入层拼接  $s$  和  $g$

### 105. 经典GoRL算法HER的做法和大致算法流程？

**问题：**GoRL奖励极其稀疏，训练初期难以得到奖励。

**HER（Hindsight Experience Replay）思路：**使用重标注（relabeling）有效利用"失败"经验——将失败轨迹中某个状态  $s''$  作为新目标  $g' = \phi(s'')$ ，这条轨迹就变成了以  $g'$  为目标的"成功"经验。

**算法流程：**

1. 初始化策略参数  $\theta$  和经验回放池  $R$
2. 对每个序列：用策略采样轨迹，以  $(s, a, r, s', g)$  形式存入  $R$
3. 从  $R$  采样；选择状态  $s''$ ，令  $g' = \phi(s'')$  计算新奖励  $r'$ ，用  $(s, a, r', s', g')$  替换原元组
4. 用新元组训练策略

注：HER框架适合各种RL方法（DQN、DDPG、PPO）。

---

## 第十四讲 多智能体强化学习

## 106. 多智能体强化学习的特点？

环境包含不断学习更新的其他智能体，在任何单个智能体视角下环境是**非稳态的 (non-stationary)**（环境迁移分布会发生改变）。智能体不仅与环境交互，还要与其他智能体交互。

## 107. 多智能体学习的难点？

将其他智能体视为环境的一部分使用单智能体Q学习，会破坏理论上的收敛保证（一个智能体策略的改变会影响其他智能体策略，环境非稳态）。理论上更加困难：单智能体（模型→学习目标→数据）vs. 多智能体（模型↔学习目标↔数据，相互影响）。

## 108. 博弈论视角下序贯决策的三种问题？

1. **马尔可夫决策过程**：一个智能体 + 多个状态
2. **重复博弈**：多个智能体 + 一个状态
3. **随机博弈（马尔可夫博弈）**：多个智能体 + 多个状态（MARL的主要框架）

## 109. 随机博弈的问题建模（博弈表格、状态转移、奖励函数、价值函数）？

元组  $(N, S, A, R, p, \gamma)$ ：

- $N$  个智能体，联合策略  $\pi = (\pi_1, \dots, \pi_N)$ ，联合动作  $a = (a_1, \dots, a_N)$
- 状态转移  $p : S \times A \rightarrow \Omega(S)$
- 各智能体奖励函数  $r_i$  在博弈表格中，每个状态对应一个博弈表格，智能体同时选择动作
- 价值函数： $V_i^\pi(s) = \sum_{t=0}^{\infty} \gamma^t \mathbb{E}_{\pi, p}[r_i^t | s_0 = s]$
- Q值函数： $Q_i^\pi(s, a) = r_i(s, a) + \gamma \mathbb{E}_{s' \sim p}[V_i^\pi(s')]$

## 110. 多智能体强化学习的方法分类？

1. **完全中心化**：所有智能体状态聚合为全局状态，所有动作连接为联合动作，优点：环境稳态；缺点：复杂度高
2. **完全去中心化**：每个智能体独立学习，假设其他智能体策略不变；优点：简单；缺点：不收敛
3. **中心化训练去中心化执行 (CTDE)**：训练时用全局信息，执行时用局部信息

## 111. 完全中心化方法：整体智能体的特点和缺点、纳什Q学习的操作步骤及缺点？

**整体智能体**：适合合作任务，奖励为各智能体之和。缺点：动作空间太大，状态转移和奖励函数复杂度高；无法处理非合作任务。

**纳什Q学习**：基于当前Q值表求解纳什均衡  $\pi^*$  和  $V_{Nash}$ ，再用纳什均衡价值更新Q值表，如此循环直至收敛。缺点：计算复杂度极高，无法处理非合作博弈。

## 112. 完全去中心化方法：优缺点、独立Q学习与独立PPO？

- **优点：**简单好实现
- **缺点：**环境非稳态，很可能不收敛

**独立Q学习：**对智能体  $i$ ，假设其他策略不变，直接做Q学习（但奖励信号实际基于联合动作）。

**独立PPO：**对每个智能体做PPO学习（可共享参数）。

### 113. CTDE算法MADDPG的特点及流程？

**特点：**

- 每个智能体是actor-critic
- **Actor**  $\mu_i(a_i|o_i)$ ：自己独有，只看局部观测
- **Critic**  $Q_i^\mu(x, a_1, \dots, a_N)$ ：所有智能体共享，有全局信息  $x = (o_1, \dots, o_N)$

**流程：**

1. 随机初始化各智能体Actor和Critic网络
2. 获取初始观测  $x$
3. 每个智能体用策略选动作（加探索噪声）
4. 执行联合动作，获得奖励和新观测
5. 存入经验回放池  $D$
6. 采样数据：中心化训练Critic（TD更新）、训练自身Actor（策略梯度）、更新目标网络

## 附录：核心公式汇总

| 算法           | 核心更新公式                                                                                                  |
|--------------|---------------------------------------------------------------------------------------------------------|
| 蒙特卡洛         | $V(S_t) \leftarrow V(S_t) + \alpha(G_t - V(S_t))$                                                       |
| TD(0)        | $V(S_t) \leftarrow V(S_t) + \alpha(R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$                               |
| SARSA        | $Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma Q(s', a') - Q(s, a))$                                   |
| Q-Learning   | $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t))$  |
| 策略梯度         | $\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a$            |
| A2C优势        | $A^{\pi}(s, a) = r(s, a) + \gamma V^{\pi}(s') - V^{\pi}(s)$                                             |
| Double DQN目标 | $y_t = r_t + \gamma Q_{\theta'}(s_{t+1}, \arg \max_{a'} Q_{\theta}(s_{t+1}, a'))$                       |
| PPO截断        | $L^{CLIP} = \mathbb{E}[\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t)]$    |
| DDPG策略梯度     | $\nabla_{\theta} J = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \pi_{\theta}(s) \nabla_a Q^{\pi}(s, a)$ |

---

本复习资料根据中国矿业大学（北京）《强化学习》课程完整课件汇总整理，覆盖所有14讲考点内容。