


第6章 隐马尔可夫模型




6.1 马尔可夫模型

6.1 马尔可夫模型

□ 马尔可夫(Andrei Andreyevich Markov) (1856.6.14 ~ 1922.7.20)

前苏联数学家。切比雪夫(1821年5月16日 ~ 1894年12月8日)的学生。在概率论、数论、函数逼近论和微分方程等方面卓有成就。他提出了用数学分析方法研究自然过程的一般图式—马尔可夫链，并开创了随机过程(马尔可夫过程)的研究。






6.1 马尔可夫模型

□ 马尔可夫模型描述

存在一类重要的随机过程：如果一个系统有 N 个状态 $S_1, S_2, \dots, S_N$ ，随着时间的推移，该系统从某一状态转移到另一状态。如果用 q_t 表示系统在时间 t 的状态变量，那么， t 时刻的状态取值为 S_j ($1 \leq j \leq N$) 的概率取决于前 $t-1$ 个时刻 ($1, 2, \dots, t-1$) 的状态，该概率为：

$$p(q_t = S_j \mid q_{t-1} = S_i, q_{t-2} = S_k, \dots)$$




6.1 马尔可夫模型

◆ 假设1:

如果在特定情况下, 系统在时间 t 的状态只与其在时间 $t-1$ 的状态相关, 则该系统构成一个离散的一阶马尔可夫链:

$$p(q_t = S_j \mid q_{t-1} = S_i, q_{t-2} = S_k, \dots) = p(q_t = S_j \mid q_{t-1} = S_i) \dots (6.1)$$




6.1 马尔可夫模型

◆ 假设2:

如果只考虑公式(6.1)独立于时间 t 的随机过程, 即所谓的不动性假设, 状态与时间无关, 那么:

$$p(q_t = S_j \mid q_{t-1} = S_i) = a_{ij}, \quad 1 \leq i, j \leq N \quad \dots (6.2)$$

该随机过程称为马尔可夫模型(Markov Model)。



6.1 马尔可夫模型

在马尔可夫模型中，状态转移概率 a_{ij} 必须满足下列条件：

$$a_{ij} \geq 0 \quad \dots (6.3)$$


$$\sum_{j=1}^N a_{ij} = 1 \quad \dots (6.4)$$


马尔可夫模型又可分为随机有限状态自动机，该有限状态自动机的每一个状态转换过程都有一个相应的概率，该概率表示自动机采用这一状态转换的可能性。

6.1 马尔可夫模型

◆ 马尔可夫链可以表示成状态图（转移弧上有概率的非确定的有限状态自动机）

- 零概率的转移弧省略。
- 每个节点上所有发出弧的概率之和等于1。






6.1 马尔可夫模型

状态序列 $S_1, \dots, S_T$ 的概率:


$$\begin{aligned} p(S_1, \dots, S_T) &= p(S_1) \times p(S_2 | S_1) \times p(S_3 | S_1, S_2) \times \dots \times p(S_T | S_1, \dots, S_{T-1}) \\ &= p(S_1) \times p(S_2 | S_1) \times p(S_3 | S_2) \times \dots \times p(S_T | S_{T-1}) \\ &= \pi_{S_1} \prod_{t=1}^{T-1} a_{S_t S_{t+1}} \quad \dots (6.5) \end{aligned}$$

其中, $\pi_i = p(q_1 = S_i)$, 为初始状态的概率。


6.1 马尔可夫模型



$$\begin{aligned} p(t, i, p) &= p(S_1 = t) \times p(S_2 = i | S_1 = t) \times p(S_3 = p | S_2 = i) \\ &= 1.0 \times 0.3 \times 0.6 \\ &= 0.18 \end{aligned}$$



6.2 隐马尔可夫模型



6.2 隐马尔可夫模型

□ 隐马尔可夫模型


(Hidden Markov Model, HMM)


创建于20世纪70年代。

描写：该模型是一个双重随机过程，我们不知道具体的状态序列，只知道状态转移的概率，即模型的状态转换过程是不可观察的（隐蔽的），而可观察事件的随机过程是隐蔽状态转换过程的随机函数。

6.2 隐马尔可夫模型

例如： N 个袋子，每个袋子中有 M 种不同颜色的球。一实验员根据某一概率分布选择一个袋子，然后根据袋子中不同颜色球的概率分布随机取出一个球，并报告该球的颜色。对局外人：可观察的过程是不同颜色球的序列，而袋子的序列是不可观察的。每只袋子对应HMM中的一个状态；球的颜色对应于 HMM 中状态的输出。






6.2 隐马尔可夫模型

□ HMM 的组成


1. 模型中的状态数为 N (袋子的数量)
2. 从每一个状态可能输出的不同的符号数 M (不同颜色球的数目)



6.2 隐马尔可夫模型

3. 状态转移概率矩阵 $A = a_{ij}$ (a_{ij} 为实验员从一只袋子 (状态 S_i) 转向另一只袋子 (状态 S_j) 取球的概率)。
其中,

$$\left\{ \begin{array}{l} a_{ij} = p(q_{t+1} = S_j \mid q_t = S_i), \quad 1 \leq i, j \leq N \\ a_{ij} \geq 0 \\ \sum_{j=1}^N a_{ij} = 1 \end{array} \right. \quad \dots (6.6)$$



6.2 隐马尔可夫模型

4. 从状态 S_j 观察到某一特定符号 v_k 的概率分布矩阵为：

$$B=b_j(k)$$

其中， $b_j(k)$ 为 实验员从第 j 个袋子中取出第 k 种颜色的球的概率。那么，

$$\left\{ \begin{array}{l} b_j(k) = p(O_t = v_k \mid q_t = S_j), \quad 1 \leq j \leq N, \quad 1 \leq k \leq M \\ b_j(k) \geq 0 \\ \sum_{k=1}^M b_j(k) = 1 \end{array} \right. \quad \dots (6.7)$$

6.2 隐马尔可夫模型

5. 初始状态的概率分布为: $\pi = \pi_i$, 其中,

$$\left\{ \begin{array}{l} \pi_i = p(q_1 = S_i), \quad 1 \leq i \leq N \\ \pi_i \geq 0 \\ \sum_{i=1}^N \pi_i = 1 \end{array} \right. \quad \dots (6.8)$$

为了方便, 一般将 HMM 记为: $\mu = (A, B, \pi)$


或者 $\mu = (S, O, A, B, \pi)$ 用以指出模型的参数集合。

6.2 隐马尔可夫模型

□ 给定HMM求观察序列

给定模型 $\mu = (A, B, \pi)$, 产生观察序列 $O = O_1 O_2 \dots O_T$:


- (1) 令 $t = 1$;**
- (2) 根据初始状态分布 $\pi = \pi_i$ 选择初始状态 $q_1 = S_i$;**
- (3) 根据状态 S_i 的输出概率分布 $b_i(k)$, 输出 $O_t = v_k$;**
- (4) 根据状态转移概率 a_{ij} , 转移到新状态 $q_{t+1} = S_j$;**
- (5) $t = t + 1$, 如果 $t < T$, 重复步骤 (3) (4), 否则结束。**



6.2 隐马尔可夫模型

□三个问题：

- (1) 在给定模型 $\mu=(A, B, \pi)$ 和观察序列 $O = O_1 O_2 \dots O_T$ 的情况下，怎样快速计算概率 $p(O|\mu)$ ？
- (2) 在给定模型 $\mu=(A, B, \pi)$ 和观察序列 $O = O_1 O_2 \dots O_T$ 的情况下，如何选择在一定意义下“最优”的状态序列 $Q = q_1 q_2 \dots q_T$ ，使得该状态序列“最好地解释”观察序列？
- (3) 给定一个观察序列 $O = O_1 O_2 \dots O_T$ ，如何根据最大似然估计来求模型的参数值？即如何调节模型的参数，使得 $p(O|\mu)$ 最大？



6.3 前向算法

6.3 前向算法

□问题1：快速计算观察序列概率 $p(O|\mu)$

给定模型 $\mu=(A, B, \pi)$ 和观察序列 $O = O_1O_2 \dots O_T$,
快速计算 $p(O|\mu)$:


对于任意的状态序列 $Q = q_1q_2\dots q_T, p(O|\mu) = ?$

$$p(O|\mu) = \sum_Q p(O, Q|\mu) = \sum_Q \boxed{p(Q|\mu)} \cdot \boxed{p(O|Q, \mu)} \quad \dots (6.9)$$


$$p(Q|\mu) = \pi_{q_1} a_{q_1q_2} a_{q_2q_3} \cdots a_{q_{t-1}q_T} \quad \dots (6.10)$$

$$p(O|Q, \mu) = b_{q_1}(O_1) \cdot b_{q_2}(O_2) \cdots b_{q_T}(O_T) \quad \dots (6.11)$$

6.3 前向算法



◆ 困难:
如果模型 μ 有 N 个不同的状态,
时间长度为 T ,
那么有 N^T 个可能的状态序列,
搜索路径成指数级组合爆炸。



6.3 前向算法

◆ 解决办法: 动态规划
前向算法(The forward procedure)

◆ 基本思想: 定义前向变量 $\alpha_t(i)$:

$$\alpha_t(i) = p(O_1 O_2 \cdots O_t, \underline{q_t} = S_i | \mu) \quad \dots(6.12)$$

如果可以高效地计算 $\alpha_t(i)$, 就可以高效地求得 $p(O|\mu)$ 。

6.3 前向算法


因为 $p(O|\mu)$ 是在到达状态 q_T 时观察到序列 $O = O_1 O_2 \dots O_T$ 的概率(所有可能的概率之和):


$$p(O|\mu) = \sum_{S_i} p(O_1 O_2 \dots O_T, q_T = S_i | \mu) = \sum_{i=1}^N \alpha_T(i) \quad \dots (6.13)$$

动态规划计算 $\alpha_t(i)$: 在时间 $t+1$ 的前向变量可以根据时间 t 的前向变量 $\alpha_t(1), \dots, \alpha_t(N)$ 的值递推计算:

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}) \quad \dots (6.14)$$

6.3 前向算法





6.3 前向算法

算法6.1:前向算法


(1)初始化: $\alpha_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$

(2)循环计算:

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), \quad 1 \leq t \leq T-1$$

(3)结束, 输出:


$$p(O | \mu) = \sum_{i=1}^N \alpha_T(i)$$




6.3 前向算法

□ 算法的时间复杂性:

每计算一个 $\alpha_t(i)$ 必须考虑从 $t-1$ 时的所有 N 个状态转移到状态 S_i 的可能性, 时间复杂性为 $O(N)$, 对应每个时刻 t , 要计算 N 个前向变量: $\alpha_t(1), \alpha_t(2), \dots, \alpha_t(N)$, 所以, 时间复杂性为: $O(N) \times N = O(N^2)$ 。又因 $t = 1, 2, \dots, T$, 所以前向算法总的复杂性为: $O(N^2T)$ 。



6.4 后向算法




6.4 后向算法

◆ 后向算法 (The backward procedure)

定义后向变量 $\beta_t(i)$ 是在给定了模型 $\mu = (A, B, \pi)$ 和假定在时间 t 状态为 S_i 的条件下, 模型输出观察序列 $O_{t+1}O_{t+2} \cdots O_T$ 的概率:

$$\beta_t(i) = p(O_{t+1}O_{t+2} \cdots O_T \mid q_t = S_i, \mu) \quad \dots (6.15)$$



6.4 后向算法

与前向变量一样，运用动态规划计算后向量：

- (1) 从时刻 t 到 $t+1$ ，模型由状态 S_i 转移到状态 S_j ，
并从 S_j 输出 O_{t+1} ；
- (2) 在时间 $t+1$ ，状态为 S_j 的条件下，模型输出观察
序列 $O_{t+2} \dots O_T$ 。

6.4 后向算法

第一步的概率: $a_{ij} \times b_j(O_{t+1})$

第二步的概率按后向变量的定义为: $\beta_{t+1}(j)$

于是, 有归纳关系:


$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j) \quad \dots (6.16)$$

归纳顺序: $\beta_T(x), \beta_{T-1}(x), \dots, \beta_1(x)$

(x 为模型的状态)

6.4 后向算法

算法图解：



6.4 后向算法

◆ 算法6.2: 后向算法


(1) 初始化: $\beta_T(i) = 1, \quad 1 \leq i \leq N$

(2) 归纳计算:


$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), \quad T-1 \geq t \geq 1, \quad 1 \leq i \leq N$$

(3) 求和输出: $p(O|\mu) = \sum_{i=1}^N \beta_1(i) \cdot \pi_i \cdot b_i(O_1)$

算法的时间复杂性: $O(N^2 T)$



6.5 Viterbi 搜索算法



6.5 Viterbi 搜索算法


□问题2 - 如何发现“最优”状态序列 能够“最好地解释”观察序列

解释不是唯一的，关键在于如何理解“最优”的状态序列？一种解释是：状态序列中的每个状态都单独地具有概率，对于每个时刻 t ($1 \leq t \leq T$), 寻找 q_t 使得 $\gamma_t(i) = p(q_t = S_i | O, \mu)$ 最大。

6.5 Viterbi 搜索算法

$$\gamma_t(i) = p(q_t = S_i | O, \mu) = \frac{p(q_t = S_i, O | \mu)}{p(O | \mu)} \quad \dots (6.17)$$

模型的输出序列 O ，并且在时间 t 到达状态 i 的概率。




6.5 Viterbi 搜索算法

分解过程:

- (1) 模型在时间 t 到达状态 i , 并且输出 $O = O_1 O_2 \dots O_t$ 。
根据前向变量的定义, 实现这一步的概率为 $\alpha_t(i)$ 。
- (2) 从时间 t , 状态 S_i 出发, 模型输出 $O = O_{t+1} O_{t+2} \dots O_T$, 根据后向变量定义, 实现这一步的概率为 $\beta_t(i)$ 。

于是:

$$p(q_t = S_i, O \mid \mu) = \alpha_t(i) \times \beta_t(i) \quad \dots (6.18)$$



6.5 Viterbi 搜索算法


而 $p(O|\mu)$ 与时间 t 的状态无关, 因此:

$$p(O|\mu) = \sum_{i=1}^N \alpha_t(i) \times \beta_t(i) \quad \dots (6.19)$$

将公式(6.18)和(6.19)带入(6.17)式得:

$$\gamma_t(i) = \frac{\alpha_t(i) \times \beta_t(i)}{\sum_{i=1}^N \alpha_t(i) \times \beta_t(i)} \quad \dots (6.20)$$

t 时刻的最优状态为: $\hat{q}_t = \arg \max_{1 \leq i \leq N} (\gamma_t(i))$




6.5 Viterbi 搜索算法


问题:

每一个状态单独最优不一定使整体的状态序列最优，可能两个最优的状态 $\hat{q}_t$ 和 $\hat{q}_{t+1}$ 之间的转移概率为0，即 $a_{\hat{q}_t \hat{q}_{t+1}} = 0$ 。


6.5 Viterbi 搜索算法



6.5 Viterbi 搜索算法



6.5 Viterbi 搜索算法



6.5 Viterbi 搜索算法

另一种解释：在给定模型 μ 和观察序列 O 的条件下求条件概率最大的状态序列：

$$\hat{Q} = \arg \max_Q p(Q | O, \mu) \quad \dots (6.21)$$

Viterbi 算法：动态搜索最优状态序列。

定义：Viterbi 变量 $\delta_t(i)$ 是在时间 t 时，模型沿着某一条路径到达 S_i ，并输出观察序列 $O = O_1 O_2 \dots O_t$ 的最大概率：

$$\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} p(q_1, q_2, \dots, q_t = S_i, O_1 O_2 \dots O_t | \mu) \quad \dots (6.22)$$

6.5 Viterbi 搜索算法

递归计算: $\delta_{t+1}(i) = \max_j [\delta_t(j) \cdot a_{ji}] \cdot b_i(O_{t+1}) \quad \dots (6.23)$

算法6.3: Viterbi 算法


(1)初始化: $\delta_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$

概率最大的路径变量 (路径记忆) : $\psi_1(i) = 0$

(2)递推计算:

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$

$$\psi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T, \quad 1 \leq i \leq N$$



6.5 Viterbi 搜索算法


(3)结束:

$$\hat{Q}_T = \arg \max_{1 \leq i \leq N} [\delta_T(i)], \quad \hat{p}(\hat{Q}_T) = \max_{1 \leq i \leq N} \delta_T(i)$$


(4)通过回溯得到路径（状态序列）：

$$\hat{q}_t = \psi_{t+1}(\hat{q}_{t+1}), \quad t = T-1, T-2, \dots, 1$$

算法的时间复杂度： $O(N^2T)$



6.6 参数学习



6.6 参数学习

□问题3 - 模型参数学习

给定一个观察序列 $O = O_1 O_2 \dots O_T$, 如何根据最大似然估计来求模型的参数值? 或者说如何调节模型 μ 的参数, 使得 $p(O|\mu)$ 最大? 即估计模型中的 $\pi_i, a_{ij}, b_j(k)$ 使得观察序列 O 的概率 $p(O|\mu)$ 最大。

前向后向算法


(Baum-Welch or forward-backward procedure)

6.6 参数学习

如果产生观察序列 O 的状态 $Q = q_1 q_2 \dots q_T$ 已知，可以用最大似然估计来计算 μ 的参数：

$$\begin{aligned} \pi_i &= \delta(q_1, S_i) \\ \bar{a}_{ij} &= \frac{Q \text{中从状态 } q_i \text{ 转移到 } q_j \text{ 的次数}}{Q \text{中所有从状态 } q_i \text{ 转移到另一状态(包括 } q_j \text{ 自身)的总数}} \\ &= \frac{\sum_{t=1}^{T-1} \delta(q_t, S_i) \times \delta(q_{t+1}, S_j)}{\sum_{t=1}^{T-1} \delta(q_t, S_i)} \quad \dots (6.24) \end{aligned}$$

其中， $\delta(x, y)$ 为克罗奈克(Kronecker)函数，当 $x=y$ 时， $\delta(x, y)=1$ ，否则 $\delta(x, y) = 0$ 。




6.6 参数学习

类似地,

$$\begin{aligned}\bar{b}_j(k) &= \frac{\text{Q中从状态 } q_j \text{ 输出符号 } v_k \text{ 的次数}}{\text{Q到达 } q_j \text{ 的总次数}} \\ &= \frac{\sum_{t=1}^T \delta(q_t, S_j) \times \delta(O_t, v_k)}{\sum_{t=1}^T \delta(q_t, S_j)} \quad \dots (6.25)\end{aligned}$$

其中, v_k 是模型输出符号集中的第 k 个符号。



6.6 参数学习

期望值最大化算法 (Expectation-Maximization, EM)

基本思想：初始化时随机地给模型的参数赋值(遵循限制规则，如：从某一状态出发的转移概率总和为 1，得到模型 μ_0 ，然后可以从 μ_0 得到从某一状态转移到另一状态的期望次数，然后以期望次数代替公式中的次数，得到模型参数的新估计，由此得到新的模型 μ_1 ，从 μ_1 又可得到模型中隐变量的期望值，由此重新估计模型参数。循环这一过程，参数收敛于最大似然估计值。


6.6 参数学习

给定模型 μ 和观察序列 $O=O_1O_2 \dots O_T$, 那么, 在时间 t 位于状态 S_i , 时间 $t+1$ 位于状态 S_j 的概率:

$$\begin{aligned}\xi_t(i, j) &= p(q_t = S_i, q_{t+1} = S_j | O, \mu) = \frac{p(q_t = S_i, q_{t+1} = S_j, O | \mu)}{p(O | \mu)} \\ &= \frac{\alpha_t(i) \times a_{ij} b_j(O_{t+1}) \times \beta_{t+1}(j)}{p(O | \mu)} \\ &= \frac{\alpha_t(i) \times a_{ij} b_j(O_{t+1}) \times \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) \times a_{ij} b_j(O_{t+1}) \times \beta_{t+1}(j)} \dots (6.26)\end{aligned}$$

6.6 参数学习

图解搜索过程：



6.6 参数学习

那么, 给定模型 μ 和观察序列 $O = O_1O_2 \dots O_T$, 在时间 t 位于状态 S_i 的概率为:

$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i, j) \quad \dots (6.27)$$

由此, 模型 μ 的参数可由下面的公式重新估计:

(1) q_1 为 S_i 的概率:

$$\pi_i = \gamma_1(i) \quad \dots (6.28)$$

6.6 参数学习

(2)

$$\bar{a}_{ij} = \frac{\text{Q中从状态 } q_i \text{ 转移到 } q_j \text{ 的期望次数}}{\text{Q中所有从状态 } q_i \text{ 转移到下一状态(包括 } q_j \text{ 自身)的期望次数}}$$

$$= \frac{\sum_{i=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad \dots (6.29)$$

(3)

$$\bar{b}_j(k) = \frac{\text{Q中从状态 } q_j \text{ 输出符号 } v_k \text{ 的期望次数}}{\text{Q到达 } q_j \text{ 的期望次数}}$$

$$= \frac{\sum_{t=1}^T \gamma_t(j) \times \delta(O_t, v_k)}{\sum_{t=1}^T \gamma_t(j)} \quad \dots (6.30)$$

6.6 参数学习

◆ 算法6.4: Baum-Welch 算法 (前向后向算法):

(1) 初始化: 随机地给 π_i , a_{ij} , $b_j(k)$ 赋值, 使得

$$\left\{ \begin{array}{ll} \sum_{i=1}^N \pi_i = 1 \\ \sum_{j=1}^N a_{ij} = 1 & 1 \leq i \leq N \\ \sum_{k=1}^M b_i(k) = 1 & 1 \leq i \leq N \end{array} \right. \quad \dots (6.31)$$

由此得到模型 μ_0 , 令 $i = 0$ 。

6.6 参数学习


(2) 执行 EM 算法:

E-步: 由模型 μ_i 根据公式 (6.26) 和 (6.27) 计算期望值 $\xi_t(i, j)$ 和 $\gamma_t(i)$ 。

M-步: 用E-步中所得到的期望值, 根据公式 (6.28-6.30) 重新估计 $\pi_i, a_{ij}, b_j(k)$ 得到模型 μ_{i+1} 。

循环: $i = i+1$, 重复执行 E-步和M-步, 直至 $\pi_i, a_{ij}, b_j(k)$ 的值收敛: $|\log p(O|\mu_{i+1}) - \log p(O|\mu_i)| < \varepsilon$ 。

(3) 结束算法, 获得相应的参数。



6.6 参数学习


□ HMM使用中注意的问题

◆ Viterbi 算法运算中的小数连乘，出现溢出
- 取对数


◆ Baum-Welch 算法的小数溢出
- 放大系数

- 参阅[Rabiner and Juang, 1993: pp. 365-368]

- 参阅 <http://htk.eng.cam.ac.uk/>



6.7 应用举例




6.7 应用举例

汉语的自动分词与词性标注问题。举例：

武汉市长江大桥于1957年9月6日竣工。

① 武汉市/N 长江/N 大桥/N 于/P 1957年9月6日/Time 竣工/V。 /Pun

② 武汉/N 市长/N 江大桥/N 于/P 1957年9月6日/Time 竣工/V。 /Pun




6.7 应用举例

用 HMM 解决问题必须考虑的几个问题：

- (1) 如何确定状态、观察及其各自的数目？**
- (2) 参数估计：初始状态概率、状态转移概率、输出概率如何确定？**

思路：


如果把汉语自动分词结果作为观察序列 $O=O_1O_2\ldots O_T$ ，那么，我们要求解的是： $\hat{O} = \arg \max p(O|\mu)$ **。对于词性标注而言，则需求解：** $\hat{Q} = \arg \max_Q p(\hat{Q}^O|O, \mu)$ **。**



6.7 应用举例

进一步解释：


- (1) 估计HMM模型 $\mu = (A, B, \pi)$ 的参数；
- (2) 对于任意给定的一个输入句子及其可能的输出序列 O ，求找所有可能的 O 中使概率 $p(O | \mu)$ 最大的解；
- (3) 快速地选择“最优”的状态序列(词性序列)，使其最好地解释观察序列。



6.7 应用举例

◆ 问题1：模型参数

- (1) 观察序列：单词序列
- (2) 状态序列：词类标记序列
- (3) 状态数目 N ：为词类标记符号的个数，如 Upenn LDC 汉语树库中有33个词类，北大语料库词类标记符号106个等；
- (4) 输出符号数 M ：每个状态可输出的不同词汇个数，如汉语介词 P 约有60个，连词 C 约有110个，即状态 P 和 C 分别对应的输出符号数为60、110。




6.7 应用举例

◆ 参数估计

(1) 如果无任何标注语料：需要一部有词性标注的词典，采用无指导学习方法：

- (a) 获取词类个数(状态数);
- (b) 获取对应每种词类的词汇数(输出符号数);
- (c) 利用 EM 迭代算法获取初始状态概率、状态转移概率和输出符号概率。




6.7 应用举例

(2)若有大规模分词和词性标注语料：有指导学习方法

咱们/rr 中国/ns 这么/rz 大{da4}/a 的{de5}/ud 一个/mq
多/a 民族/n 的{de5}/ud 国家/n 如果/c 不/df 团结/a ,
/wd 就/d 不/df 可能/vu 发展/v 经济/n , /wd 人民/n生
活/n 水平/n 也/d 就/d 不/df 可能/vu 得到/v 改善/vn和
{he2}/c 提高/vn 。 /wj

可以从这些标注语料中抽取出所有的词汇和词类标记，并用最大似然估计方法计算各种概率。



6.7 应用举例


$$\pi_{\text{pos}_i} = \frac{\text{POS}_i \text{出现在句首的次数}}{\text{所有句首的个数}}$$

$$\bar{a}_{ij} = \frac{\text{从词类POS}_i \text{转移到POS}_j \text{的次数}}{\text{所有从状态POS}_i \text{转移到另一POS(包括POS}_j \text{)的总数}}$$

$$\bar{b}_j(k) = \frac{\text{从状态POS}_j \text{输出词汇 } w_k \text{ 的次数}}{\text{状态POS}_j \text{ 出现的总次数}}$$

6.7 应用举例

一般来说，需要通过错误驱动的机器学习方法修正模型的参数：



6.7 应用举例

◆ 问题2：如何获取观察序列？

- 借助于其他工具，获得 n -best 的粗切分。

本地主叫通话时长1400分钟。

——→ 本地/ 主叫/ 通话/ 时长/ 1400/ 分钟/ 。
本/ 地主/ 叫/ 通话/ 时/ 长/ 1400/ 分钟/ 。
本/ 地主/ 叫/ 通话/ 时长/ 1400/ 分钟/ 。

负责任 ——→ 负/ 责任
负责/ 任
负/ 责/ 任

6.7 应用举例

◆ 分词实验：以“负责任”为例
利用部分《人民日报》语料。

词类 词	A	C	Q	NF	NG	NL	V	VN	总计
负责	4	0	0	0	0	0	177	50	231
任	0	4	11	59	2	4	98	0	178
其他	34469	25475	24232	11453	4550	25670	184488	42674	
总计	34473	25479	24243	11512	4552	25674	184763	42724	



6.7 应用举例

$O_1 = w_1 w_2 =$ 负责/ 任

$$p(O_1|\mu) = 5.4 \times 10^{-6}$$

$O_2 = w_1 w_2 =$ 负/ 责任


$$p(O_2|\mu) = 9.3 \times 10^{-4}$$

$O_3 = w_1 w_2 w_3 =$ 负/ 责/ 任

$$p(O_3|\mu) = 4.3 \times 10^{-6}$$

$$p(O_2|\mu) > p(O_1|\mu) > p(O_3|\mu)$$


第二种切分结果可能性较大：负/ 责任



6.7 应用举例

◆ 分词性能测试:


- (1) 封闭测试: 《人民日报》1998年1月份的部分切分和标注语料, 约占训练语料的1/10, 计78396个词, 含中国人名1273个。(人名识别前)准确率: 90.34%。
- (2) 开放测试: 《人民日报》1998年2月份的部分切分和标注语料, 也占训练语料的1/10, 共82347个词, 含中国人名2316个。(人名识别前)准确率: 86.32%。



6.7 应用举例

◆ 词性标注: $\hat{Q} = \arg \max_Q p(Q | O, \mu)$

- (1) 采用有指导的参数估计方法;
- (2) 训练语料: 北京大学标注的《人民日报》2000年1、2、4月份的语料;
- (3) 封闭测试: 2000年2月20-29日的标注语料, 词性标注的精确率为: 95.16%;
- (4) 开放测试: 2000年3月1-7日的语料, 词性标注的精确率为: 88.45%。



本章小结

□ HMM 的构成:


状态数

输出符号数

初始状态的概率分布

状态转移的概率

输出概率



本章小结

□ HMM 的三个基本问题：

(1) 快速计算给定模型的观察序列的概率

- 前向算法或后向算法

(2) 求最优状态序列

- Viterbi 算法

(3) 参数估计

- Baum-Welch (Forward-Backward) 算法

□ 模型实现中需要注意的问题：小数溢出