

第9章 句法分析

(1/2)

9.1 概述

9.1 概述



- ◆ 任务: 句法分析(syntactic parsing)的任务就是识别句子的句法结构(syntactic structure)。
- ◆ 类型:
 - 短语结构分析(Phrase parsing)
 - 完全句法分析(Full parsing)
 - 局部句法分析(Partial parsing)
 - 依存句法分析(Dependency parsing)

9.2 短语结构分析

9.2 短语结构分析



◆ 句法分析的例子（参见前面第4章）


他还提出一系列具体措施的政策要点。

他/PN 还/AD 提出/VV 一/CD 系列/M 具体/JJ
措施/NN 和/CC 政策/NN 要点/NN 。/PU

9.2 短语结构分析




(IP (NP-SBJ (PN 他))
 (VP (ADVP (AD 还))
 (VP (VV 提出))
 (NP-OBJ(QP (CD 一)
 (CLP (M 系列))))
 (NP (NP(ADJP (JJ 具体)
 (NP (NN 措施))))
 (CC 和)
 (NP (NN 政策)
 (NN 要点))))))
 (PU 。))



9.2 短语结构分析

树状表示:



9.2 短语结构分析



- ◆ 目标: 实现高正确率、高鲁棒性 (**robustness**)、高速度的自动句法分析过程。
- ◆ 困难: 自然语言中存在大量的复杂的结构歧义 (**structural ambiguity**)。

9.2 短语结构分析



◆ 结构歧义

例如：(1) I saw a boy **in the park**.

[I saw a boy] in the park.

I saw a [boy in the park].

(2) I saw a boy **in the park** **with a telescope**.

(3) I saw a boy swimming **on the bridge**.

(4) 关于鲁迅的文章。

(5) 把重要的书籍和手稿带走了。


9.2 短语结构分析



英语中的结构歧义随介词短语组合个数的增加而不断加深的，这个组合个数我们称之为开塔兰数(Catalan number，记作 C_N)。

如果句子中存在这样 n (n 为自然数)个介词短语， C_N 可由下式获得 [Samuelsson, 2000]:

$$C_N = \binom{2n}{n} \frac{1}{n+1} = \frac{(2n)!}{(n!)^2 (n+1)}$$



9.2 短语结构分析

◆ 基本方法和开源的句法分析器:

➤ 基于CFG规则的分析方法:

✧ 线图分析法(chart parsing)

✧ CYK 算法

✧ Earley (厄尔利)算法

✧ LR 算法/ Tomita 算法

— Top-down: Depth-first/ Breadth-first

— Bottom-up

9.2 短语结构分析



- 基于PCFG 的分析方法

PCFG: Probabilistic Context-Free Grammar
(有时也写作Stochastic CFG, SCFG)

- 其他统计模型

- 部分开源的句法分析器

9.3 线图分析法

9.3 线图分析法



◆ 三种策略


- 自底向上 (**Bottom-up**)
- 从上到下 (**Top-down**)
- 从上到下和从下到上结合

9.3 线图分析法



◆ 自底向上的Chart 分析算法

- 给定一组CFG 规则: $XP \rightarrow \alpha_1 \dots \alpha_n$ ($n \geq 1$)
- 给定一个句子的词性序列: $S = W_1 W_2 \dots W_n$
- 构造一个线图: 一组结点和边的集合;




- 建立一个二维表: 记录每一条边的起始位置和终止位置。

9.3 线图分析法



执行操作：查看任意相邻几条边上的词性串是否与某条重写规则的右部相同，如果相同，则增加一条新的边跨越原来相应的边，新增加边上的标记为这条重写规则的头(左部)。重复这个过程，直到没有新的边产生。



9.3 线图分析法




点规则：用于表示规则右部被归约(reduce)的程度。

设有规则：NP $\longrightarrow$ Det A N

NP $\longrightarrow$ Det N NP $\longrightarrow$ A N

句子：The good book



NP $\longrightarrow$ Det $\circ$ A N
 $\longrightarrow$

NP $\longrightarrow$ Det $\circ$ N
 $\longrightarrow$

NP $\longrightarrow$ Det A $\circ$ N
 $\longrightarrow$

NP $\longrightarrow$ Det A N $\circ$
 $\longrightarrow$

9.3 线图分析法


点规则：用于表示规则右部被归约(reduce)的程度。

设有规则：NP $\longrightarrow$ Det A N

NP $\longrightarrow$ Det N

NP $\longrightarrow$ A N

句子：The good book



9.3 线图分析法



◆ 数据结构

- **线图(Chart)**: 保存分析过程中已经建立的成分(包括终结符和非终结符)、位置(包括起点和终点)。通常以 $n \times n$ 的数组表示(n 为句子包含的词数)。
- **代理表(待处理表)(Agenda)**: 记录刚刚得到的一些重写规则所代表的成分, 这些重写规则的右端符号串与输入词性串(或短语标志串)中的一段完全匹配, 通常以栈或线性队列表示。
- **活动边集(ActiveArc)**: 记录那些右端符号串与输入串的某一段相匹配, 但还未完全匹配的重写规则, 通常以数组或列表存储。

9.3 线图分析法




◆ 算法描述:

从输入串的起始位置到最后位置，循环执行如下步骤：

(1) 如果待处理表(Agenda)为空，则找到下一个位置上的词，将该词对应的(所有)词类 X 附以 (i, j) 作为元素放到待处理表中，即 $X(i, j)$ 。其中， i, j 分别是该词的起始位置和终止位置， $j > i$ ， $j - i$ 为该词的长度。

(2) 从 Agenda 中取出一个元素 $X(i, j)$ 。



(3) 对于每条规则 $A \rightarrow X\gamma$ ，将 $A \rightarrow X \circ \gamma$ (i, j) 加入活动边集ActiveArc 中，然后调用扩展弧子程序。

9.3 线图分析法



✧ 扩展弧子程序:

- (a) 将 X 插入图表(Chart)的 (i, j) 位置中。
- (b) 对于活动边集(ActiveArc)中每个位置为 (k, i) ($1 \leq k < i$) 的点规则, 如果该规则具有如下形式: $A \rightarrow \alpha \circ X$, 如果 $A=S$, 则把 $S(1, n+1)$ 加入到Chart 中, 并给出一个完整的分析结果; 否则, 则将 $A(k, j)$ 加入到Agenda表中。
- (c) 对于每个位置为 (k, i) 的点规则: $A \rightarrow \alpha \circ X \beta$, 则将 $A \rightarrow \alpha X \circ \beta (k, j)$ 加入到活动边集中。

9.3 线图分析法



例: $G(S): S \rightarrow NP \ VP, NP \rightarrow Det \ N$

$VP \rightarrow V \ NP, VP \rightarrow VP \ PP$

$PP \rightarrow Prep \ NP$

输入句子: the boy hits the dog with a rod

①形态分析: the boy hit the dog with a rod

A diagram illustrating the morphological analysis of the sentence "the boy hits the dog with a rod". The words of the sentence are aligned with their corresponding morphological forms below them. Red dashed arrows point from each word to its morphological form: "the" to "the", "boy" to "boy", "hits" to "hit", "the" to "the", "dog" to "dog", "with" to "with", "a" to "a", and "rod" to "rod". The word "hit" is highlighted in blue, and a solid red arrow points to it from above.

9.3 线图分析法



例: $G(S): S \rightarrow NP \ VP, NP \rightarrow Det \ N$

$VP \rightarrow V \ NP, VP \rightarrow VP \ PP$

$PP \rightarrow Prep \ NP$

输入句子: the boy hits the dog with a rod

①形态分析: the boy hit the dog with a rod

②词性标注: Det N V Det N Prep Det N

9.3 线图分析法

③ 句法分析

Agenda

ActiveArc

Chart


Acts

Det (1, 2)

$NP \rightarrow Det \circ N$ (1,2)

Det (1, 2)

返回



(1) $S \rightarrow NP VP$

(2) $NP \rightarrow Det N$

(3) $VP \rightarrow VP PP$


(4) $VP \rightarrow V NP$

(5) $PP \rightarrow Prep NP$

9.3 线图分析法

③ 句法分析

Agenda	ActiveArc	Chart	Acts
Det (1, 2)	$NP \rightarrow Det \circ N$ (1,2)	Det (1, 2)	返回
N (2, 3)	无新的活动边加入	N (2, 3)	扩展



(1) $S \rightarrow NP VP$
 (4) $VP \rightarrow V NP$


(2) $NP \rightarrow Det N$
 (5) $PP \rightarrow Prep NP$

(3) $VP \rightarrow VP PP$

9.3 线图分析法

③ 句法分析

Agenda	ActiveArc	Chart	Acts
Det (1, 2)	$NP \rightarrow Det \circ N (1,2)$	Det (1, 2)	返回
N (2, 3)	$NP \rightarrow Det \circ N (1,3)$	N (2, 3)	扩展
NP (1, 3)	$S \rightarrow NP \circ VP (1,3)$	NP (1, 3)	返回
V (3, 4)	$VP \rightarrow V \circ NP (3,4)$	V (3, 4)	返回



(1) $S \rightarrow NP VP$
 (4) $VP \rightarrow V NP$

(2) $NP \rightarrow Det N$
 (5) $PP \rightarrow Prep NP$


(3) $VP \rightarrow VP PP$

9.3 线图分析法



③ 句法分析

Agenda	ActiveArc	Chart	Acts
Det (4, 5)	$NP \rightarrow Det \circ N$ (4,5)	Det (4, 5)	返回
N (5, 6)	无新的活动边加入	N (5, 6)	扩展



(1) $S \rightarrow NP VP$
 (4) $VP \rightarrow V NP$


(2) $NP \rightarrow Det N$
 (5) $PP \rightarrow Prep NP$

(3) $VP \rightarrow VP PP$


9.3 线图分析法



最后分析结果:



9.3 线图分析法



将上图中的边改为
结点，将结点改为
边，得到分析结果
的直观图。

9.3 线图分析法




◆ Chart parsing 算法评价

➤ 优点:

- 算法简单，容易实现，开发周期短。

➤ 弱点:

- 算法效率低，时间复杂度为 Kn^3 ;
(n 为句子长度, K 为常量)
- 需要高质量的规则，分析结果与规则质量密切相关;
- 难以区分歧义结构。



9.4 CYK分析算法

9.4 CYK分析算法

◆ Cocke-Younger-Kasami (CYK) 算法

- 对Chomsky 文法进行范式化:

$$A \rightarrow w \text{ 或 } A \rightarrow BC$$

$$A, B, C \in V_N, w \in V_T, G=(V_N, V_T, P, S)$$

- 自下而上的分析方法
- 构造 $(n+1) \times (n+1)$ 识别矩阵, n 为输入句子长度。
假设输入句子 $x=w_1w_2\dots w_n$, w_i 为构成句子的单词
, $n=|x|$ 。


9.4 CYK分析算法



◆ 识别矩阵的构成

- 方阵对角线以下全部为0
- 主对角线以上的元素由文法G的非终结符构成
- 主对角线上的元素由输入句子的终结符号(单词)构成

9.4 CYK分析算法




9.4 CYK分析算法



◆ 识别矩阵构造步骤

- (1) 首先构造主对角线，令 $t_{0,0}=0$ ，然后，从 $t_{1,1}$ 到 $t_{n,n}$ 在主对角线的位置上依次放入输入句子 x 的单词 w_i 。
- (2) 构造主对角线以上紧靠主对角线的元素 $t_{i, i+1}$ ，其中， $i = 0, 1, 2, \dots, n-1$ 。对于输入句子 $x = w_1 w_2 \dots w_n$ ，从 w_1 开始分析。



9.4 CYK分析算法



如果在文法 G 的产生式集中有一条规则：

$$A \rightarrow w_1$$

则 $t_{0,1}=A$ 。

依此类推，如果有 $A \rightarrow w_{i+1}$ ，则 $t_{i,i+1}=A$ 。

即，对于主对角线上的每一个终结符 w_i ，所有可能推导出它的非终结符写在它的右边主对角线上方的位置上。



9.4 CYK分析算法



(3) 按平行于主对角线的方向，一层一层地向上填写矩阵的各个元素 $t_{i,j}$ ，其中， $i = 0, 1, \dots, n-d$ ， $j = d+i$ ， $d=2, 3, \dots, n$ 。如果存在一个正整数 k ， $i+1 \leq k \leq j-1$ ，在文法 G 的规则集中有产生式 $A \rightarrow BC$ ，并且， $B \in t_{i,k}$ ， $C \in t_{k,j}$ ，那么，将 A 写到矩阵 $t_{i,j}$ 位置上。

判断句子 x 由文法 G 所产生的充要条件是： $t_{0,n}=S$ 。

9.4 CYK分析算法



9.4 CYK分析算法



◆ 例子

给定文法 $G(S)$:

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

(4) $P \rightarrow \text{他}$

(5) $V \rightarrow \text{喜欢}$

(6) $V \rightarrow \text{读}$

(7) $N \rightarrow \text{书}$

请用CYK 算法分析句子：他喜欢读书

9.4 CYK分析算法



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

	0	1	2	3	4
0	0	P			
1		他	V	VP	
2			喜欢	V	
3				读	N
4					书

9.4 CYK分析算法



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

	0	1	2	3	4
0	0	P → P			
1		他	V → VP		
2			喜欢	V	N
3				读	N
4					书

9.4 CYK分析算法



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

	0	1	2	3	4
0	0	P	P	S	
1		他	V	VP	?
2			喜欢	V	N
3				读	N
4					书

9.4 CYK分析算法



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

	0	1	2	3	4
0	0	P → P			
1		他	V → VP → VP		
2			喜欢	V	N
3				读	N
4					书

9.4 CYK分析算法



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1) $S \rightarrow P \ VP$
(2) $VP \rightarrow V \ V$
(3) $VP \rightarrow VP \ N$

	0	1	2	3	4
0	0	P →	P →	P	
1		他	V →	VP →	VP
2			喜欢	V	N
3				读	N
4					书

Diagram illustrating the CYK analysis process for the sentence "他喜欢读书" (He likes to read a book). The matrix shows the decomposition of the sentence into phrases (P, VP, V, N) and the corresponding words (他, 喜欢, 读, 书). Red arrows indicate the flow of the analysis, showing how the sentence is built up from the words. A red oval highlights the empty cell at (3,1), indicating that the phrase "他" (He) is not part of a VP.

9.4 CYK分析算法



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。


(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

	0	1	2	3	4
0	0	P → P → P → S			
1		他	V → VP → VP		
2			喜欢	V → N	
3				读	N
4					书

9.4 CYK分析算法



9.4 CYK分析算法




◆ CYK 算法的评价

◆ 优点

- 简单易行，执行效率高

◆ 弱点

- 必须对文法进行范式化处理
- 无法区分歧义



9.5 概率上下文无关文法

9.5 概率上下文无关文法



◆ PCFG 规则

形式: $A \rightarrow \alpha, p$

约束: $\sum_{\alpha} p(A \rightarrow \alpha) = 1$

例如: $\left. \begin{array}{l} \text{NP} \rightarrow \text{NN NN}, 0.60 \\ \text{NP} \rightarrow \text{NN CC NN}, 0.40 \end{array} \right\} \Sigma p = 1$

$\left. \begin{array}{l} \text{CD} \rightarrow \text{QP}, 0.99 \\ \text{CD} \rightarrow \text{LST}, 0.01 \end{array} \right\} \Sigma p = 1$



9.5 概率上下文无关文法





◆ 例-1: $S \rightarrow NP VP, 1.00$ $NP \rightarrow NP PP, 0.40$
 $NP \rightarrow \text{astronomers}, 0.10$
 $NP \rightarrow \text{ears}, 0.18$ $NP \rightarrow \text{saw}, 0.04$
 $NP \rightarrow \text{stars}, 0.18$ $NP \rightarrow \text{telescopes}, 0.1$
 $PP \rightarrow P NP, 1.00$ $P \rightarrow \text{with}, 1.00$
 $VP \rightarrow V NP, 0.70$ $VP \rightarrow VP PP, 0.30$
 $V \rightarrow \text{saw}, 1.00$

给定句子 S: *Astronomers saw stars with ears.*

9.5 概率上下文无关文法



9.5 概率上下文无关文法






9.5 概率上下文无关文法

◆ 计算分析树概率的基本假设

- **位置不变性:** 子树的概率与其管辖的词在整个句子中所处的位置无关, 即对于任意的 k , $p(A_{k(k+C)} \rightarrow w)$ 一样。
- **上下文无关性:** 子树的概率与子树管辖范围以外的词无关, 即 $p(A_{kl} \rightarrow w | \text{任何超出 } k \sim l \text{ 范围的上下文}) = p(A_{kl} \rightarrow w)$ 。
- **祖先无关性:** 子树的概率与推导出该子树的祖先结点无关, 即 $p(A_{kl} \rightarrow w | \text{任何除 } A \text{ 以外的祖先结点}) = p(A_{kl} \rightarrow w)$ 。

9.5 概率上下文无关文法



t_1 : S 1.00 ?

NP 0.10

Astronomers

VP 0.70

V 1.00

saw

NP 0.40

NP 0.18

stars

PP 1.00

P 1.00

with

NP 0.18


ears

$$\begin{aligned} p(\text{tree}_{\text{PP}}) &= p(\text{P} \rightarrow \text{with}) \\ &\quad \times p(\text{NP} \rightarrow \text{ears}) \\ &\quad \times p(\text{PP} \rightarrow \text{P NP}) \\ &= 1.00 \times 0.18 \times 1.00 \\ &= 0.18 \end{aligned}$$

$$\begin{aligned} p(\text{tree}_{\text{NP}}) &= \\ p(\text{NP} \rightarrow \text{astronomers}) &= 0.10 \end{aligned}$$

$$\begin{aligned} p(\text{tree}_{\text{NP}}) &= p(\text{NP} \rightarrow \text{stars}) \times \\ &= p(\text{tree}_{\text{PP}}) \times p(\text{NP} \rightarrow \text{NP PP}) \\ &= 0.18 \times 0.18 \times 0.4 \\ &= \underline{0.01296} \end{aligned}$$

9.5 概率上下文无关文法



t_1 :

S 1.00

?

NP 0.10

VP 0.70

$$\begin{aligned} p(\text{tree}_{VP}) &= p(V \rightarrow \text{saw}) \times \\ & p(\text{tree}_{NP}) \times p(VP \rightarrow V \text{ NP}) \\ &= 1.0 \times 0.01296 \times 0.70 \\ &= 0.009072 \end{aligned}$$

$$\begin{aligned} p(t_1) &= p(\text{tree}_{NP}) \times p(VP) \times p(S \rightarrow NP \text{ VP}) \\ &= 0.10 \times 1.0 \times 0.009072 \\ &= 0.0009072 \end{aligned}$$

$p(\text{tree}_{NP})$

$p(NP \rightarrow \text{astronomers}) = 0.10$

saw

NP 0.18

PP 1.00

stars

P 1.00



NP 0.18

with

ears

$$\begin{aligned} p(\text{tree}_{NP}) &= p(NP \rightarrow \text{stars}) \times \\ &= p(\text{tree}_{PP}) \times p(NP \rightarrow NP \text{ PP}) \\ &= 0.18 \times 0.18 \times 0.4 \\ &= \underline{0.01296} \end{aligned}$$

9.5 概率上下文无关文法




$$\begin{aligned} p(t_2) &= 1.00 \times 0.10 \times 0.30 \times \\ &\quad 0.70 \times 1.00 \times 0.18 \times \\ &\quad 1.00 \times 1.00 \times 0.18 \\ &= 0.0006804 \end{aligned}$$


9.5 概率上下文无关文法



对于给定的句子 S ，两棵句法分析树的概率不等， $P(t_1) > P(t_2)$ ，因此，可以得出结论：分析结果 t_1 正确的可能性大于 t_2 。



9.6 PCFG的三个问题



9.6 PCFG的三个问题

- 1、给定句子 $W=w_1w_2\dots w_n$ 和PCFG G ，如何快速计算 $p(W|G)$ ？
- 2、给定句子 $W=w_1w_2\dots w_n$ 和PCFG G ，如何快速的选择最佳句法结构树？
- 3、给定句子 $W=w_1w_2\dots w_n$ 和PCFG G ，如何调节 G 的参数，使得 $p(W|G)$ 最大？

9.6 PCFG的三个问题



假设文法 $G(S)$ 的规则只有两种形式:

$$A \rightarrow w, \quad w \in V_T$$

$$A \rightarrow BC, \quad B, C \in V_N$$

可以通过范式化处理, 使CFG 规则满足上述形式。这种假设的文法形式称为乔姆斯基范式(Chomsky normal form, CNF)。




9.6 PCFG的三个问题

1、内向算法或外向算法解决第一个问题 —快速地计算句子的句法树概率

◆ 内向算法

基本思想：利用动态规划算法计算由非终结符 A 推导出的某个字串片段 $w_i w_{i+1} \dots w_j$ 的概率 $\alpha_{ij}(A)$ 。语句 $W = w_1 w_2 \dots w_n$ 的概率即为文法 $G(S)$ 中 S 推导出的字串的概率 $\alpha_{1n}(S)$ 。



9.6 PCFG的三个问题

- 定义：内向变量 $\alpha_{ij}(A)$ 是由非终结符 A 推导出的语句 W 中子字符串 $w_i w_{i+1} \dots w_j$ 的概率：


$$\alpha_{ij}(A) = p(A \Rightarrow^* w_i w_{i+1} \dots w_j)$$

计算 $\alpha_{ij}(A)$ 的递推公式：

$$\alpha_{ii}(A) = p(A \rightarrow w_i)$$

$$\alpha_{ij}(A) = \sum_{B, C \in V_N} \sum_{i \leq k \leq j} p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$$

9.6 PCFG的三个问题



9.6 PCFG的三个问题



➤解释:

当 $i=j$ 时, 字符串 $w_i w_{i+1} \dots w_j$ 只是一个字 w_{ii} , 可简单记作 w_i , 由 A 推导出 w_i 的概率就是产生式 $A \rightarrow w_i$ 的概率 $p(A \rightarrow w_i)$; 当 $i \neq j$ 时, 也就是说, 字符串 $w_i w_{i+1} \dots w_j$ 至少有两个词, 根据约定, A 要推导出该词串, 必须首先运用产生式 $A \rightarrow BC$, 那么, 可用 B 推导出前半部 $w_i \dots w_k$, 用 C 推导出后半部 $w_{k+1} \dots w_j$ 。由这一推导过程产生 $w_i w_{i+1} \dots w_j$ 的概率为: $p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$ 。考虑到 B 、 C 和 k 取值的任意性, 应计算各种情况下概率的总和。

9.6 PCFG的三个问题



➤ 内向算法描述:

输入: 文法 $G(S)$, 语句 $W = w_1 w_2 \dots w_n$

输出: $p(S \Rightarrow^* w_1 w_2 \dots w_n)$


(1) 初始化: $\alpha_{ii}(A) = p(A \rightarrow w_i) \quad A \in V_N, 1 \leq i \leq n$

(2) 归纳计算: $j=1 \dots n, i=1 \dots n-j$, 重复下列计算:

$$\alpha_{i(i+j)}(A) = \sum_{B, C \in V_N} \sum_{i \leq k \leq i+j} p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)(i+j)}(C)$$

(3) 终结: $p(S \Rightarrow^* w_1 w_2 \dots w_n) = \alpha_{1n}(S)$

9.6 PCFG的三个问题



内向归纳，自底向上。

9.6 PCFG的三个问题



◆ 外向算法

➤ 定义:

外向变量 $\beta_{ij}(A)$ 是由文法初始符号 S 推导出语句 $W = w_1 w_2 \dots w_n$ 的过程中, 到达扩展符号串 $w_1 \dots w_{i-1} \textcircled{A} w_{j+1} \dots w_n$ 的概率 ($A = w_i \dots w_j$):


$$\beta_{ij}(A) = p(S \xRightarrow{*} w_1 \dots w_{i-1} \textcircled{A} w_{j+1} \dots w_n)$$

$\beta_{ij}(A)$ 表示除了以 A 为根节点的子树以外的概率。

9.6 PCFG的三个问题



s 自顶向下外向扩展





9.6 PCFG的三个问题



$\beta_{ij}(A)$ 可由动态规划算法求得, 其递推公式:

$$\beta_{1n}(A) = \delta(A, S) \quad (\text{初始化})$$

$$\beta_{ij}(A) = \sum_{B,C} \sum_{k>j} \beta_{ik}(B) p(B \rightarrow AC) \alpha_{(j+1)k}(C) + \sum_{B,C} \sum_{k<i} \beta_{kj}(B) p(B \rightarrow CA) \alpha_{k(i-1)}(C)$$




9.6 PCFG的三个问题



➤ 解释:

(1) 当 $i=1, j=n$ 时, 即 $w_i w_{i+1} \dots w_j$ 是整个语句 W 时, 根据乔姆斯基语法范式的约定, 不可能有规则 $S \rightarrow A$, 因此, 由 S 推导出 W 的过程中, 如果 $A \neq S$ 的话, A 推导出 W 的概率为 0 (只有 S 才能推导出 W), 即 $\beta_{1n}(A)=0$ 。

如果 $A=S$, $\beta_{1n}(A)$ 为由初始符 S 推导出 W 的概率, 因此, $\beta_{1n}(A)=1$ 。



9.6 PCFG的三个问题

(2) 当 $i \neq 1$ 或者 $j \neq n$ 时, 如果在 S 推导出 W 的过程中出现了字符串 $w_1 \dots w_k A w_{j+1} \dots w_n$, 则该推导过程必定使用了规则 $B \rightarrow AC$ 或 $B \rightarrow CA$ 。假定运用了规则 $B \rightarrow AC$ 推导出 $w_i \dots w_j w_{j+1} \dots w_k$, 则该推导可以分解为以下三步:

(a) 由 S 推导出 $w_1 \dots w_{i-1} B w_{k+1} \dots w_n$, 其概率为 $\beta_{ik}(B)$;

(b) 运用产生式 $B \rightarrow AC$ 扩展非终结符 B , 其概率为 $p(B \rightarrow AC)$;

(c) 由非终结符 C 推导出 $w_{j+1} \dots w_k$, 其概率为 $\alpha_{(j+1)k}(C)$ 。

9.6 PCFG的三个问题



考虑到 B , C 和 k 的任意性, 在计算 $\beta_{ik}(B)$ 时, 必须考虑所有可能的 B , C 和 k , 因此, 计算概率时必须考虑所有情况下的概率之和。

同样方法, 可以计算出运用产生式 $B \rightarrow CA$ 推导出 $w_k \cdots w_{i-1} w_i \cdots w_j$ 的概率。

9.6 PCFG的三个问题



➤ 外向算法描述:

输入: PCFG $G=(S, N, T, P)$, 语句 $W = w_1 w_2 \dots w_n$;

输出: $\beta_{ij}(A)$, $A \in N$, $1 \leq i \leq j \leq n$ 。

(1) 初始化: $\beta_{1n}(A) = \delta(A, S)$, $A \in N$;

(2) 归纳: j 从 $n-1$ 到 0 , i 从 1 到 $n-j$, 重复计算:

$$\begin{aligned} \beta_{i(i+j)}(A) = & \sum_{B,C} \sum_{i+j < k \leq n} p(B \rightarrow AC) \alpha_{(i+j+1)k}(C) \beta_{ik}(B) \\ & + \sum_{B,C} \sum_{1 \leq k < i} p(B \rightarrow CA) \alpha_{k(i-1)}(C) \beta_{k(i+j)}(B) \end{aligned}$$

(3) 终结: $p(S \Rightarrow^* w_1 w_2 \dots w_n) = \beta_{1n}(S)$

9.6 PCFG的三个问题

2、Viterbi 算法解决第二个问题

一 最佳分析结果搜索

➤ 定义:

Viterbi 变量 $\gamma_{ij}(A)$ 是由非终结符 A 推导出语句 W 中子字符串 $w_i w_{i+1} \dots w_j$ 的最大概率。

注意: γ 区别于内向算法中的 α 。

变量 $\psi_{i,j}$ 用于记忆字符串 $W = w_1 w_2 \dots w_n$ 的 Viterbi 语法分析结果。

9.6 PCFG的三个问题



➤ Viterbi 算法描述:

输入: 文法 $G(S)$, 语句 $W = w_1 w_2 \dots w_n$

输出: $\gamma_{1n}(S)$

(1) 初始化: $\gamma_{ii}(A) = p(A \rightarrow w_i) \quad A \in V_N, 1 \leq i \leq n$

(2) 归纳计算: $j=1..n, i=1..n-j$, 重复下列计算:

$$\gamma_{i(i+j)}(A) = \max_{B, C \in V_N; i \leq k \leq i+j} p(A \rightarrow BC) \gamma_{ik}(B) \gamma_{(k+1)(i+j)}(C)$$

$$\psi_{i(i+j)}(A) = \max_{B, C \in V_N; i \leq k \leq i+j} p(A \rightarrow BC) \gamma_{ik}(B) \gamma_{(k+1)(i+j)}(C)$$

(3) 终结: $p(S \xRightarrow{*} w_1 w_2 \dots w_n) = \gamma_{1n}(S)$



9.6 PCFG的三个问题

3、内外向算法解决第三个问题—参数估计

➤ 基本思路

如果有大量已标注语法结构的训练语料，则可直接通过计算每个语法规则的使用次数，用最大似然估计方法计算PCFG规则的概率参数，即：

$$\hat{p}(N^j \rightarrow \zeta) = \frac{C(N^j \rightarrow \zeta)}{\sum_{\gamma} C(N^j \rightarrow \gamma)}$$



9.6 PCFG的三个问题

多数情况下，没有可利用的标注语料，只好借助EM (Expectation Maximization) 迭代算法估计PCFG的概率参数。

初始时随机地给参数赋值，得到语法 G_0 ，依据 G_0 和训练语料，得到语法规则使用次数的期望值，以期望次数运用于最大似然估计，得到语法参数新的估计值，由此得到新的语法 G_1 ，由 G_1 再次得到语法规则的使用次数的期望值，然后又重新估计语法参数。循环这个过程，语法参数将收敛于最大似然估计值。

9.6 PCFG的三个问题



◆ 内外向算法

给定CFG G 和训练数据 $W = w_1 w_2 \dots w_n$, 语法规则 $A \rightarrow BC$ 使用次数的期望值为:

$$\begin{aligned} \text{Count}(A \rightarrow BC) &= \sum_{1 \leq i \leq k \leq j \leq n} p(A_{ij}, B_{ik}, C_{(k+1)j} \mid w_1 \dots w_n, G) \\ &= \frac{1}{p(w_1 \dots w_n \mid G)} \sum_{1 \leq i \leq k \leq j \leq n} p(A_{ij}, B_{ik}, C_{(k+1)j}, w_1 \dots w_n \mid G) \\ &= \frac{1}{p(w_1 \dots w_n \mid G)} \sum_{1 \leq i \leq k \leq j \leq n} \beta_{ij}(A) p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C) \\ &\quad \dots \text{(NW1)} \end{aligned}$$

9.6 PCFG的三个问题



➤解释：给定语句 $W = w_1 \dots w_n$ ，

PCFG G 中产生式 $A \rightarrow BC$

在产生 W 的过程中被使用


次数的期望值为：在所有

可能的情况下，即在条件：

$1 \leq i \leq k \leq j \leq n$ 下， W 的语

法分析结构中 $w_i \dots w_k$ 由 B 导出， $w_{k+1} \dots w_j$ 由 C 导出，

$w_i \dots w_j$ 由 A 导出的概率总和。



9.6 PCFG的三个问题



类似地，语法规则 $A \rightarrow a$ 的使用次数的期望值为：

$$\begin{aligned} \text{Count}(A \rightarrow a) &= \sum_{1 \leq i \leq n} p(A_{ii} \mid w_1 \cdots w_n, G) \\ &= \frac{1}{p(w_1 \cdots w_n \mid G)} \sum_{1 \leq i \leq n} p(A_{ii}, w_1 \cdots w_n \mid G) \\ &= \frac{1}{p(w_1 \cdots w_n \mid G)} \sum_{1 \leq i \leq n} \beta_{ii}(A) p(A \rightarrow a) \delta(a, w_i) \end{aligned}$$

... (NW2)

9.6 PCFG的三个问题



G 的参数可由下面的公式重新估计:

$$\hat{p}(A \rightarrow \mu) = \frac{Count(A \rightarrow \mu)}{\sum_{\mu} Count(A \rightarrow \mu)} \quad \dots \text{(NW3)}$$

其中, μ 要么为终结符号, 要么为两个非终结符号串, 即 $A \rightarrow \mu$ 为乔姆斯基语法范式要求的两种形式。

9.6 PCFG的三个问题



➤ 内外向算法:

(1) 初始化: 随机地给 $p(A \rightarrow \mu)$ 赋值, 使得

$$\sum_{\mu} p(A \rightarrow \mu) = 1, \text{ 由此得到语法 } G_0. \text{ 令 } i=0;$$

(2) EM迭代:

E-步: 由 G_i 根据公式(NW1)和(NW2), 计算期望值 $Count(A \rightarrow BC)$ 和 $Count(A \rightarrow a)$;

M-步: 用 E-步所得的期望值, 根据公式(NW3)重新估计 $p(A \rightarrow \mu)$, 得到 G_{i+1} 。

(3) 循环: $i=i+1$, 重复EM步骤, 直至 $p(A \rightarrow \mu)$ 值收敛。

9.6 PCFG的三个问题



◆ PCFG 的评价


➤ 优点:

- 可利用概率减少分析过程的搜索空间;
- 可利用概率对概率较小的子树剪枝, 加快分析效率;
- 可以定量地比较两个语法的性能。

➤ 弱点:

- 分析树的概率计算条件非常苛刻, 甚至不够合理。

9.7 短语结构分析 方法评估




9.7 短语结构分析方法评估

◆ 内部评测 (intrinsic evaluation)

一对评测方法本身的评测，用于指导句法分析系统及其语法的开发过程。主要指标有：

- 语法的覆盖性 (grammatical coverage)
- 平均分析基数 (average parse base)
- 结构一致性 (structural consistency)
- 排序的一致性 (best-first/ranked consistency)等



9.7 短语结构分析方法评估

◆ 对比评测(comparative evaluation)

用于对比不同系统之间的性能差别，主要评测指标和方法包括：

- 树相似性(tree similarity)
- 模型的熵(或困惑度)(entropy/perplexity)
- 语法评估兴趣小组(grammar evaluation interest group, GIEG)的评测方案等



9.7 短语结构分析方法评估

◆ 句法分析器性能评测

目前使用比较广泛的句法分析器评价指标是 PARSEVAL 测度，三个基本的评测指标：

- 精度(precision)：句法分析结果中正确的短语个数所占的比例，即分析结果中与标准分析树（答案）中的短语相匹配的个数占分析结果中所有短语个数的比例，即：



9.7 短语结构分析方法评估

$$P = \frac{\text{分析得到的正确的短语个数}}{\text{分析得到的所有的短语个数}} \times 100\%$$

- 召回率(recall): 句法分析结果中正确的短语个数占标准分析树中全部短语个数的比例, 即:

$$R = \frac{\text{分析得到的正确的短语个数}}{\text{标准树库中(答案)的短语个数}} \times 100\%$$

- F-measure: $F = \frac{(\beta^2 + 1) \times P \times R}{\beta^2 \times P + R} \times 100\%$


一般地, $\beta=1$, 称作 $F1$ 测度。



9.7 短语结构分析方法评估

- 交叉括号数(crossing brackets): 一棵分析树中与其他分析树中边界相交叉的成分个数的平均值。

分析树中除了词性标注符号以外的其他非终结符节点通常采用如下标记格式: **XP-(起始位置: 终止位置)**。其中, **XP**为短语名称; **(起始位置: 终止位置)**为该节点的跨越范围, **起始位置**指该节点所包含的子节点的起始位置, **终止位置**为该节点所包含的子节点的终止位置。在计算PARSEVAL指标时, 通常需要计算分析结果与标准分析树之间括号匹配的数目或括号交叉的数目。




9.7 短语结构分析方法评估


- ◆ 例如：下面的图(a)为句子“*Sales executives were examining the figures with great care yesterday.*”的正确分析树(标准答案)。

9.7 短语结构分析方法评估

(a) 句法分析实例 (标准答案)




在标准答案树中，除了词性标注符号以外(即除了叶子节点和其直接父节点以外)的其他非终结符节点(短语)有：**S-(0:11)**, **NP-(0:2)**, **VP-(2:9)**, **VP-(3:9)**, **NP-(4:6)**, **PP-(6:9)**, **NP-(7:9)**, ***NP-(9:10)**。




9.7 短语结构分析方法评估

(b) 系统分析结果



在系统输出的分析树中，除了词性标注符号以外的其他非终结符节点(短语)有：

S-(0:11), NP-(0:2),
VP-(2:10), VP-(3:10),
NP-(4:10), NP-(4:6),
PP-(6:10), NP-(7:10)。



9.7 短语结构分析方法评估

标准答案: S-(0:11), NP-(0:2), VP-(2:9), VP-(3:9), NP-(4:6), PP-(6:9), NP-(7:9), *NP-(9:10)

系统结果: S-(0:11), NP-(0:2), VP-(2:10), VP-(3:10), NP-(4:10), NP-(4:6), PP-(6:10), NP-(7:10)

只有这3个短语与标准答案完全一样，因此，

$$\text{Precision} = \frac{3}{8} \times 100\% = 37.5\%$$

$$\text{Recall} = \frac{3}{8} \times 100\% = 37.5\%$$

注：图(a)中加*号的一元的节点(*NP)在计算时应该被排除在外，但在这里也被包括进来了。




9.7 短语结构分析方法评估

➤ 另外两个指标:

① 词性标注的准确率(tagging accuracy)。在该句子的分析树中，11个词中除了*great* 被错误地标注以外，其他的词性标注均为正确的，因此，词性标注准确率为 $10/11=90.9\%$

② 交叉括号数(crossing brackets)和交叉准确率(crossing accuracy): 在本例中不存在交叉括号，因此，交叉括号数为0，交叉准确率为100%。



9.7 短语结构分析方法评估

PARSEVAL评测方法的区分能力不是很强，而且在某些特殊情况下计算出的正确率和召回率存在较大的偏差。因此，有关专家提出了一些其他的评测方法，如基于依存结构的评测方法[D. Lin, 1995]、基于语法关系的评测方法[J. Carroll, 1998]等等。

Lin, Dekang. 1995. A dependency-based method for evaluating broad-coverage parsers. In *Proceedings of the IJCAI-95*, Montreal, Canada, pp 1420-1425

Carroll, John, Ted Briscoe, and Antonio Sanfilippo. 1998. Parser Evaluation: a Survey and a New Proposal. In *Proceedings of the First Conference on Linguistic Resources*, pp 447-455



9.7 短语结构分析方法评估

◆ 利用宾州树库语料对 **Berkeley Parser** 的测试情况：

◆ 性能表现：

语种	训练集	开发集	测试集
汉语(句子数)	18089	350	348
英文(句子数)	39832	1700	2416

语种	句子类型	正确率(%)	召回率(%)	F1
英语	长度小于等于40个词	90.7	90.5	90.6
	所有的句子	90.2	89.8	90.5
汉语	长度小于等于40个字	86.9	85.7	86.3
	所有的句子	84.8	81.9	83.32