

第11章 机器翻译

本章内容



11.1 机器翻译概论

11.2 统计机器翻译

11.1 机器翻译概论



11.1.1 引言

- ◆ 有关专家已经指出，语言障碍是**21**世纪国际社会全球化面临的主要困难之一；
- ◆ 机器翻译涉及语言学、计算语言学、认知科学和数学等多种学科，具有重要的科学意义；
- ◆ 机器翻译具有巨大的社会需求，不仅具有极大的经济利益，而且对于情报获取、信息安全意义重大；
- ◆ 以欧洲为例，有**380**多种语言，**2004**年**5**月**1**日以前欧盟有**11**种官方语言，每年为这**11**种语言翻译、转录文件耗费的人力费用大约 **549M** 欧元。**2014**年欧盟**24**种官方工作语言。

11.1.2 机器翻译的 产生与发展

11.1.2 机器翻译的产生与发展

- ◆ 概念：机器翻译 (machine translation, MT) 是用计算机把一种语言(源语言, source language) 翻译成另一种语言(目标语言, target language) 的一门学科和技术。



11.1.2 机器翻译的产生与发展




- ◆ 古希腊时期
- ◆ 17世纪：笛卡儿(Descartes)莱布尼兹(Leibniz)试图用统一的数字代码编写词典；17世纪中叶贝克(Cave Beck)等人出版类似的词典。

11.1.2 机器翻译的产生与发展



- ◆ **1930s**: 亚美尼亚法国工程师阿尔楚尼(G. B. Arsouni)提出了用机器来进行语言翻译的想法，并在1933年7月22日获得了一项“翻译机”的专利，叫做机器脑(mechanical brain)。



11.1.2 机器翻译的产生与发展



- ◆ **1933年**，前苏联发明家特洛扬斯基设计了用机械方法把一种语言翻译成为另一种语言的机器。
- ◆ **1946年**，世界上第一台电子计算机 ENIAC 诞生以后，英国工程师 A. D. Booth 和美国洛克菲勒基金会 (Rockefeller Foundation) 副总裁 W. Weaver 提出了利用计算机进行机器翻译的设想。
- ◆ **1947年3月**，W. Weaver 给 N. Wiener 写信，讨论机器翻译问题，但遭到了 N. Wiener 的反对。
- ◆ **1949年**，W. Weaver 发表了以 ‘Translation’ 为题目的备忘录，正式提出机器翻译问题。

11.1.2 机器翻译的产生与发展



翻译类似于解读密码的过程：
当我阅读一篇用俄语写的文章时，
我可以说这篇文章实际上是用英文
写的，只不过它用另外一种奇怪的
符号编了码，当我阅读时，我是在
进行解码。--1949

11.1.2 机器翻译的产生与发展



原文和译文“说的是同样的事情”，因此，当把语言A翻译为语言B时，就意味着，从语言A出发，经过某一“通用语言 (universal language)”或“中间语言 (interlingua)”，然后转换为语言B，这种“通用语言”或“中间语言”可以假定是全人类共同的。



11.1.2 机器翻译的产生与发展

- ◆ 美国和英国的学术界对机器翻译产生了浓厚的兴趣，并得到了实业界的支持。
- ◆ 1954年Georgetown 大学在IBM 协助下，用IBM-701 计算机实现了世界上第一个 MT 系统，实现俄译英翻译，1954年1月该系统在纽约公开演示。系统只有250条俄语词汇，6 条语法规则，可以翻译简单的俄语句子。
- ◆ 随后10 多年里，MT研究在国际上出现热潮。

草创时期

11.1.2 机器翻译的产生与发展



- ◆ **1964年**，美国科学院成立语言自动处理咨询委员会 (Automatic Language Processing Advisory Committee, ALPAC)，调查机器翻译的研究情况，并于1966年 11月公布了一个题为“**语言与机器**”的报告，简称 **ALPAC 报告**，宣称：“在目前给机器翻译以大力支持还没有多少理由”，“机器翻译遇到了难以克服的语义障碍 (semantic barrier)”。从此，机器翻译研究在世界范围内进入低迷状态。



11.1.2 机器翻译的产生与发展

- ◆ 1970 ~ 1976年，法国、日本、加拿大等国，仍坚持机器翻译研究，而且，在这一阶段语法与算法分开，机器翻译研究开始复苏。代表系统：法国 GETA, IMAG-CLIPS 开发的 ARIANE-78 系统。

复苏阶段




11.1.2 机器翻译的产生与发展

◆ 1976~至今

繁荣时期

- 加拿大蒙特利尔大学与加拿大联邦政府翻译局联合开发的实用机器翻译系统 TAUM-METEO，用于天气预报翻译。每小时可以翻译6~30万个词；每天翻译1500—2000篇天气预报资料，并通过电视、报纸等立即公布；
- 1978年欧共体启动多语言机器翻译计划；
- 1982 ~ 1986，日本在提出第五代机的同时，研究日英双向机器翻译系统 Mu 和亚洲多语言机器翻译（日语、汉语、印尼语、马来西亚语、泰国语）；
- 1990年，IBM 提出统计机器翻译模型，机器翻译研究进入了一个空前辉煌的繁荣时期。

11.1.3 机器翻译的困难




11.1.3 机器翻译的困难

- ◆ 自然语言中普遍存在的歧义和未知现象
 - 句法结构歧义/词汇歧义/语用歧义 ...
 - 新的词汇、术语、结构、语义 ...
- ◆ 机器翻译不仅仅是字符串的转换
 - 不同语言之间文化的差异
 - 现有方法无法表示和利用世界知识和常识
- ◆ 机器翻译的解不唯一，而且始终存在着人为的标准

几乎自然语言处理中的所有问题在机器翻译中都会遇到。

11.1.3 机器翻译的困难



食品或菜单名的翻译：

- (1) 红烧狮子头: **Fried Lion's Head**
→ **Braised pork balls**
- (2) 夫妻肺片: **Husband and wife's lung slices**
→ **Fuqifeipian / Spicy beef**
- (3) 童子鸡: **Young lad chicken**
Boy chicken without sexual life
→ **Spring chicken / Broiler chicken**


11.1.3 机器翻译的困难



11.1.3 机器翻译的困难



11.1.4机器翻译研究现状



11.1.4 机器翻译研究现状

◆ 若干翻译系统已实用化或接近实用化

- Google translator (<http://translate.google.com>)
- Systran (<http://www.systransoft.com>)
- TAUM-METEO
- 百度在线翻译/ 华建英汉翻译系统/ 金山词霸 等

◆ 仍面临若干问题

- 理论模型和方法
- 实现技术问题
- 用户认识问题

应彻底消除对机器翻译的误解
让机器翻译系统翻译诗歌、散文和小说等高难度文艺作品是不现实的，也是不可能的。

11.1.4 机器翻译研究现状



黛玉自在枕上感念宝钗……又听见窗外竹梢焦叶之上，雨声淅沥，消寒透幕，不觉又滴下泪来。


(《红楼梦》第45回)

As she lay there alone, Dai-Yu's thoughts turned to Bao- chai ...Then she listened to the insistent rustle of the rain on the bamboos and plantains outside her window. The coldness penetrated the curtains of her bed. Almost without noticing it she had begun to cry.

—文学翻译家David Hawkes

摘自冯志伟著《机器翻译研究》，2004

11.1.4 机器翻译研究现状



Google Translator (<http://translate.google.com/>, 2017.4.16):

Daiyu comfortable pillow on the feeling of Chai Chai and heard the bamboo leaves above the leaves above the rain, rain pattering, cold through the curtain, feel and dripping tears.

机器不是人，更不是文学翻译家！

11.1.4 机器翻译研究现状



◆ 基本观点

在机器翻译研究中实现人机共生(man-machine symbiosis), 人机互助比追求完全自动的高质量的翻译(Full Automatic High Quality Translation, FAHQT) 更现实、更切合实际[Hutchins, 1995]。

我们需要的是计算机帮助人类完成某些翻译工作, 而不是完全替代人, 人与机器翻译系统之间应该是互补的关系, 而不是相互竞争[Hutchins, 2001].

11.1.4 机器翻译研究现状



机器翻译研究在过去的五十多年曲折发展经历中，无论是它给人们带来的希望还是失望我们都必须客观地看到，机器翻译作为一个科学问题在被学术界不断深入研究的同时，企业家们已经从市场上获得了相应的利润。

- ✧ 机器翻译还不成熟(state-of-the-art)，需要的是人与系统的配合，而不是有意为难，辅助机器翻译可以大大减轻人的负担。
- ✧ “信、达、雅”是人类翻译追求的目标，计算机在这方面永远都不会替代人。

11.1.5 基本翻译方法

11.1.5 基本翻译方法



- ◆ 直接转换法
- ◆ 基于规则的翻译方法
- ◆ 基于中间语言的翻译方法
- ◆ 基于语料库的翻译方法
 - 基于事例的翻译方法
 - 统计翻译方法
 - 神经网络机器翻译

11.1.5 基本翻译方法



◆ 直接转换法

从源语言句子的表层出发，将单词、短语或句子直接置换成目标语言译文，必要时进行简单的词序调整。对原文句子的分析仅满足于特定译文生成的需要。这类翻译系统一般针对某一个特定的语言对，将分析与生成、语言数据、文法和规则与程序等都融合在一起。例如：

I like Mary.

Me(I) gusta(like)

Maria(Mary). X like Y

Y X gusta

11.1.5 基本翻译方法



◆ 基于规则的翻译方法(Rule-based)

1957 年美国学者 V. Yingve 在《句法翻译框架》(Framework for Syntactic Translation) 一文中提出了对源语言和目标语言均进行适当描述、把翻译机制与语法分开、用规则描述语法的实现思想，这就是基于规则的翻译方法。

11.1.5 基本翻译方法



基于规则的翻译过程分成6个步骤：

- (a) 对源语言句子进行词法分析
- (b) 对源语言句子进行句法/语义分析
- (c) 源语言句子结构到译文结构的转换
- (d) 译文句法结构生成
- (e) 源语言词汇到译文词汇的转换
- (f) 译文词法选择与生成

11.1.5 基本翻译方法




给定源语言句子: **There is a book on the desk.**

■ 词法分析:


There/Ad is/V_{be} a/Det book/N on/P the/Det desk/N ./Puc

■ 利用句法规则进行句法结构分析:




11.1.5 基本翻译方法

■ 利用转换规则将
源语言句子结构转
换成目标语言句子
结构




11.1.5 基本翻译方法

■ 利用转换规则将
源语言句子结构转
换成目标语言句子
结构




11.1.5 基本翻译方法

■ 利用转换规则将
源语言句子结构转
换成目标语言句子
结构



11.1.5 基本翻译方法

■ 利用转换规则将
源语言句子结构转
换成目标语言句子
结构



11.1.5 基本翻译方法



➤ 将源语言词汇翻译成目标语言词汇

# there	Ad: 在那里
# be	V _{be} : 是
# there be	VP: 在...有
# a	Det: 一，一个，一本...
# book	N: 书，书籍; V: 预订

➤ 译文词法处理和目标语言句子生成:

在桌子上有一本书。

11.1.5 基本翻译方法



由于基于规则的翻译方法执行过程为：

“独立分析—独立生成—相关转换”因此，又称**基于转换的翻译方法**。

其代表系统是法国格勒诺布尔(Grenoble)机器翻译研究所(GETA)开发的ARIANE翻译系统。

1976年加拿大蒙特利尔大学与加拿大联邦翻译局联合开发的实用性机器翻译系统 TAU-METEO：天气预报信息服务。

11.1.5 基本翻译方法



对基于规则的翻译方法的评价：

优点：可以较好地保持原文的结构，产生的译文结构与源文的结构关系密切，尤其对于语言现象已知的或句法结构规范的源语言语句具有较强的处理能力和较好的翻译效果。


弱点：规则一般由人工编写，工作量大，主观性强，一致性难以保障，不利于系统扩充，对非规范语言现象缺乏相应的处理能力。

11.1.5 基本翻译方法



◆ 基于中间语言的翻译方法(Interlingua-based)

- **方法:** 输入语句 → 中间语言 → 翻译结果
- **代表系统:** JANUS (CMU) 早期版本
 - ★ 源语言解析器
 - ★ 比较准确的中间语言(Interlingua)
 - ★ 目标语言生成器(Target Language Generator)



11.1.5 基本翻译方法



◆ 关于中间语言的定义

- 国际先进语音翻译研究联盟(C-STAR)定义的中间转换格式 (Interchange Format, IF)
- 日本东京联合国大学(United Nations University)提出的通用网络语言 (Universal Networking Language, UNL)

11.1.5 基本翻译方法



对基于中间语言的翻译方法评价：

优点： 中间语言的设计可以不考虑具体的翻译语言对，因此，该方法尤其适合多语言之间的互译。

弱点： 如何定义和设计中间语言的表达方式，以及如何维护并不是一件容易的事情，中间语言在语义表达的准确性、完整性等很多方面，都面临若干困难。

11.1.5 基本翻译方法

◆ 基于事例(实例)的翻译方法 (Example-based)


1984年由日本学者长尾真提出。



1936年出生，1959年毕业于京都大学工学系电子工学专业，1961年京都大学研究生院硕士课程毕业，1966年从京都大学获得工学博士称号，1973年担任京都大学教授，1997年担任京都大学校长，2004年担任信息通信研究机构(NICT)理事长，2007年4月起担任日本国立国会图书馆馆长。研究开发的业绩涉及自然语言处理、图像处理、信息工学、智能信息学等多个领域。2003年获得ACL终生成就奖。

11.1.5 基本翻译方法

- **方法：** 输入语句→与事例相似度比较
 - →翻译结果
- **资源：** 大规模事例库
- **代表系统：** ATR-MATRIX (ATR, Japan)



11.1.5 基本翻译方法



对基于实例的翻译方法评价：

优点：不要求源语言句子必须符合语法规则，翻译机制一般不需要对源语言句子做深入分析。

弱点：两个不同的句子之间的相似性（包括结构相似性和语义相似性）往往难以把握，尤其在口语中，句子结构一般比较松散，成分冗余和成分省略都较严重，这更增加了分析句子与事例句子的比较难度。另外，系统往往难以处理事例库中没有记录的陌生的语言现象，而且当事例库达到一定规模时，其事例检索的效率较低。


11.1.5 基本翻译方法



◆ 其它翻译方法

- 基于记忆的(memory-based)翻译方法
- 统计翻译方法(statistical method)
- 基于多引擎的翻译方法(multi-engine)
- 基于神经网络(neural network)的翻译方法

11.1.5 基本翻译方法



本讲小结



- ◆ 机器翻译的产生与发展
- ◆ 机器翻译研究现状
- ◆ 机器翻译基本方法
 - 直接转换法
 - 基于规则的翻译方法
 - 基于中间语言的翻译方法
 - 基于事例的翻译方法