

第11章 机器翻译（二）

11.2 统计机器翻译

11.2.1 统计翻译的诞生



- 1990年IBM的Peter F. Brown 等人在*Computational Linguistics* 上发表论文“统计机器翻译方法” [Brown, 1990]; 1993年他们发表在该杂志发表论文“统计机器翻译的数学：参数估计” [Brown, 1993], 两篇文章奠定了统计机器翻译的理论基础。



左: **Robert Mercer**

右: **Peter F. Brown**


11.2.1 统计翻译基本原理



◆ 噪声信道模型

一种语言 T 由于经过一个噪声信道而发生变形，从而在信道的另一端呈现为另一种语言 S (信道意义上的输出，翻译意义上的源语言)。翻译问题实际上就是如何根据观察到的 S ，恢复最为可能的 T 问题。这种观点认为，任何一种语言的任何一个句子都有可能是另外一种语言中的某个句子的译文，只是可能有大有小 [Brown *et. al*, 1990]。





11.2.1 统计翻译基本原理

源语言句子: $S = s_1^m = s_1 s_2 \cdots s_m$

目标语言句子: $T = t_1^l = t_1 t_2 \cdots t_l$



贝叶斯公式: $P(T|S) = \frac{P(T) \times P(S|T)}{P(S)}$

$$T' = \operatorname{argmax}_T P(T) \times P(S|T)$$

语言模型
Language model, LM

翻译模型
Translation model, TM

11.2.1 统计翻译基本原理



$$P(T|S) = \frac{P(T) \times P(S|T)}{P(S)}$$

统计翻译中的三个关键问题:

- (1) 估计语言模型概率 $p(T)$;
- (2) 估计翻译概率 $p(S|T)$;
- (3) 快速有效地搜索 T 使得 $p(T) \times p(S|T)$ 最大。

11.2.1 统计翻译基本原理




◆ 估计语言模型概率 $p(T)$

给定句子: $T = t_1^l = t_1 t_2 \cdots t_l$

句子概率: $P(T) = P(t_1)P(t_2|t_1) \cdots P(t_l|t_1 t_2 \cdots t_{l-1})$

n -gram 问题, 不再赘述。




11.2.1 统计翻译基本原理

◆ 翻译概率 $p(S|T)$ 的计算

关键问题是怎样定义目标语言句子中的词与源语言句子中的词之间的对应关系。

假设英语与法语的翻译对：





11.2.1 统计翻译基本原理


不妨，我们用 $A(S,T)$ 表示源语言句子 S 与目标语言句子 T 之间所有对位关系的集合。在目标语言句子 T 的长度（单词的个数）为 l ，源语言句子 S 的长度为 m 的情况下， T 和 S 的单词之间有 $l \times m$ 种不同的对应关系。由于一个对位是由词之间的对应关系决定的，并且不同的对应方式应该是 $2^{l \times m}$ 的子集，因此， $A(S,T)$ 中共用 $2^{l \times m}$ 种对位。

对于一个给定的句对 $(S|T)$ ，我们可以假定所有的单词对 (s_j, t_i) 之间存在着对应关系。那么，用来刻画这些对应关系的模型叫做对位模型 (alignment model)。

11.2.1 统计翻译基本原理



统计翻译系统的基本构成





11.2.1 统计翻译基本原理

□ 数学问题

求解联合概率分布 $p(S=S, A=A, T=T)$ ，其中， S, T 分别表示源语言和目标语言字符串随机变量， A 为 S 与 T 之间的对位关系的随机变量。 S, A, T 分别表示随机变量 S, A, T 的一个具体取值。

约定用 l, m 分别表示目标语言句子的长度和源语言句子的长度，现在我们约定 L 和 M 分别表示长度 l 和 m 的随机变量。在不引起混淆的情况下，我们一般用 $p(S, A, T)$ 替代 $p(S=S, A=A, T=T)$ 。

11.2.1 统计翻译基本原理



翻译句对 $(S|T)$ 的似然率可以通过条件概率

$p(S, A|T)$ 获得:
$$P(S|T) = \sum_A P(S, A|T)$$


按照约定, 源语言句子 $S = s_1^m = s_1 s_2 \cdots s_m$ 有 m 个单词

目标语言句子 $T = t_1^l = t_1 t_2 \cdots t_l$ 有 l 个单词

每一种对位序列表示成:

$$A = a_1^m = a_1 a_2 \cdots a_m \quad a_j \in [0, 1, \cdots, l]$$

11.2.1 统计翻译基本原理



$$l = 6 \quad m = 7$$

$$a_1 = 2, a_2 = 3, a_3 = 4, a_4 = 5, a_5 = 6, a_6 = 6, a_7 = 6$$

$$A = a_1^m = (2, 3, 4, 5, 6, 6, 6)$$

11.2.1 统计翻译基本原理



◆ 翻译概率 $p(S|T)$ 的计算

$$P(S|T) = \sum_A P(S, A|T)$$

→ $P(S, A|T)$?

$$P(S, A|T) = p(m|T) \times \underbrace{P(A|T, m)}_{\text{对位模型}} \times \underbrace{P(S|T, A, m)}_{\text{词汇翻译模型}}$$

对位模型

词汇翻译模型

11.2.1 统计翻译基本原理



$$\begin{aligned} P(S, A|T) &= p(m|T) \times P(A|T, m) \times P(S|T, A, m) \\ &= p(m|T) \prod_{j=1} p(a_j|a_1^{j-1}, s_1^{j-1}, m, T) \times p(s_j|a_1^j, s_1^{j-1}, m, T) \end{aligned}$$

实际上， $p(S, A|T)$ 可以写成多种形式的条件概率的乘积，上式只是其中的一种。在上式的基础上，IBM 的研究人员通过采用不同的假设条件得到了5个翻译模型，分别称作 IBM 翻译模型1、2、3、4 和 5。

11.2.2 IBM 翻译模型1

11.2.2 IBM 翻译模型1



$$P(S, A|T) = p(m|T) \prod_{j=1}^m p(a_j|a_1^{j-1}, s_1^{j-1}, m, T) \times p(s_j|a_1^j, s_1^{j-1}, m, T)$$

翻译模型1：

(1) 假设 $\varepsilon \equiv p(m|T)$ 是一个较小的常量；

(2) 假设 $a_j \sim \text{uniform}(0, 1, 2, \dots, l)$ $p(a_j|a_1^{j-1}, s_1^{j-1}, m, T) = \frac{1}{l+1}$


(3) 假设 $s_j \sim \text{Categorical}(\theta_{t_{a_j}})$ $p(s_j|a_1^j, s_1^{j-1}, m, T) = p(s_j|t_{a_j})$

11.2.2 IBM 翻译模型1



$$\begin{aligned} P(S, A|T) &= p(m|T) \prod_{j=1}^m p(a_j | a_1^{j-1}, s_1^{j-1}, m, T) \times p(s_j | a_1^j, s_1^{j-1}, m, T) \\ &= \varepsilon \prod_{j=1}^m \frac{1}{l+1} \times p(s_j | t_{a_j}) \\ &= \frac{\varepsilon}{(l+1)^m} \prod_{j=1}^m p(s_j | t_{a_j}) \end{aligned} \quad (1)$$

11.2.2 IBM 翻译模型1



$$P(S, A|T) = \frac{\varepsilon}{(6 + 1)^7} \times [p(Le|the) \times \dots \times p(application|implemented)]$$

共7项

(2)

11.2.2 IBM 翻译模型1



由于对位关系由1到 m 个 a_j 的具体值所决定，而每个 a_j 的值可以是0到 l 之间的任意数，因此，

$$p(S | T) = \frac{\varepsilon}{(l+1)^m} \sum_{a_1=0}^l \cdots \sum_{a_m=0}^l \prod_{j=1}^m p(s_j | t_{a_j}) \quad (3)$$

对于(3)式，我们需要知道所有词对 $(s|t)$ 的概率 p 使得翻译概率 $p(S|T)$ 最大，并且对于每一个给定的单词 t 满足以下约束条件：

$$\sum_s p(s | t) = 1$$



11.2.2 IBM 翻译模型1

为了求解限定条件下概率 $p(S|T)$ 的最大值，我们引入拉格朗日乘法因子 λ_t ，然后，求下列辅助函数的无限定条件的极大值：

$$h(p, \lambda) \equiv \frac{\varepsilon}{(l+1)^m} \sum_{a_1}^l \cdots \sum_{a_m}^l \prod_{j=1}^m p(s_j | t_{a_j}) - \sum_t \lambda_t (\sum_s p(s | t) - 1)$$

根据求最大值的条件， h 函数关于 p 和 λ 的偏导数应等于零。函数 h 关于 $p(s|t)$ 的偏导数为：

11.2.2 IBM 翻译模型1




$$\frac{\partial h}{\partial p(s|t)} = \frac{\varepsilon}{(l+1)^m} \sum_{a_1=0}^l \square \sum_{a_m=0}^l \sum_{j=1}^m \delta(s, s_j) \delta(t, t_{a_j}) p(s|t)^{-1} \prod_{k=1}^m p(s_k | t_{a_k}) - \lambda_t$$

其中， δ 是 **Kronecker** 函数，当它的两个参数相同时， $\delta=1$ ，否则， $\delta=0$ 。这样，在偏导数等于0 情况下，可以求得

$$p(s|t) = \lambda_t^{-1} \frac{\varepsilon}{(l+1)^m} \sum_{a_1=0}^l \square \sum_{a_m=0}^l \sum_{j=1}^m \delta(s, s_j) \delta(t, t_{a_j}) \prod_{k=1}^m p(s_k | t_{a_k})$$

(4)



11.2.2 IBM 翻译模型1

公式(4) 提供了一种利用迭代过程求解最大值的思路：给翻译概率一个任意的初始估计值，我们可以计算出等式右边的值，并可以利用这个值作为新的 $p(s|t)$ 的估计值。这个重复进行的迭代过程正是期望最大化(EM)算法：

借助(2)式，可以将(4)式写成如下形式：

$$p(s | t) = \lambda_t^{-1} \sum_A P(S, A | T) \sum_{j=1}^m \delta(s, s_j) \delta(t, t_{a_j}) \quad (5)$$


对位A中t 连接到s 的次数

11.2.2 IBM 翻译模型1



忽略详细的数学推导，IBM 翻译模型1表示为如下等式：

$$p(S | T) = \frac{\varepsilon}{(l+1)^m} \prod_{j=1}^m \sum_{i=0}^l p(s_j | t_i) \quad (6)$$



11.2.2 IBM 翻译模型1

根据IBM翻译模型1，由英语句子 e 生成法语句子 f 的实现过程：

- (1) 根据概率分布为法语句子 f 选择一个长度 m ；
- (2) 对于每一个 $j = 1, 2, \dots, m$ ，根据均匀分布原则从 $0, 1, \dots, l$ 中选择一个值给 a_j ；
- (3) 对于每一个 $j = 1, 2, \dots, m$ ，根据概率选择一个法语单词 f_j 。

11.2.3 IBM 翻译模型2

11.2.3 IBM 翻译模型2



在IBM 模型2中，除了假定概率 $P(a_j | a_1^{j-1}, s_1^{j-1}, m, T)$ 依赖于位置 j 、对位关系 a_j 和源语言句子长度 m 以及目标语言句子长度 l 以外，另外两个假设与IBM模型1中的假设一样。

引入了对位概率(alignment probabilities)的概念：

$$a(a_j | j, m, l) \equiv P(a_j | a_1^{j-1}, s_1^{j-1}, m, l)$$

11.2.3 IBM 翻译模型2

对于每一个三元组 (j, m, l) ，对位概率满足如下约束条件：


$$\sum_{i=0}^l a(i | j, m, l) = 1$$

类似于IBM模型1的推导，得到模型2：

$$p(S | T) = \varepsilon \prod_{j=1}^m \sum_{i=0}^l p(s_j | t_i) \times a(i | j, m, l) \quad (7)$$

如果对位概率 $a(i | j, m, l)$ 设为常数，IBM 模型2退化为模型1，即模型1是模型2的特例。

$$p(S | T) = \frac{\varepsilon}{(l+1)^m} \prod_{j=1}^m \sum_{i=0}^l p(s_j | t_i)$$



11.2.3 IBM 翻译模型2

根据 IBM模型2，由英语句子 e 生成法语句子 f 的实现过程：

- (1) 根据概率分布为法语句子 f 选择一个长度 m ;
- (2) 对于每一个 $j = 1, 2, \dots, m$ ，根据概率分布 $a(a_j | j, l, m)$ 从 $0, 1, \dots, l$ 中选择一个值给 a_j ;
- (3) 对于每一个 $j = 1, 2, \dots, m$ ，根据概率选择一个法语单词 f_j 。

11.2.6 基于短语的 翻译模型

11.2.6 基于短语的翻译模型



□ 基本思想 [Koehn, 2003] (Phrase-based)

将一个法语句子 f 翻译成英语句子 e :

$$\operatorname{argmax}_e p(e \mid f) = \operatorname{argmax}_e p(f \mid e)p(e)$$

考虑到位置的调整:

$$e_{best} = \operatorname{argmax}_e p(f \mid e)p(e)\omega^{length(e)}$$

ω 为长度因子, 一般 $\omega > 1$, 倾向于较长的输出。

11.2.6 基于短语的翻译模型



◆ 注意：

这里所说的短语指一个连续的字串(*n*-gram), 不一定是语言学中定义的短语(*phrase*), 如:

我想预订一个单人间。

I would like to reserve a single room.

11.2.6 基于短语的翻译模型



- ◆ 模板对位模型[Ney, 2000; Och, 2002等]
 - ◆ 采用基于类的模型，解决数据稀疏问题。运用双语词聚类技术，将两种语言的每一个词都对应到一个类中，共计使用了400个类。
 - ◆ 在语言模型上，采用基于类的 5-gram, back-off 数据平滑方法；

11.2.6 基于短语的翻译模型



- ◆ 在翻译模型上，提出了对齐模板(alignment template)的方法，实现两种层次的对齐：短语层次的对齐和词语层次的对齐，对齐模板采用基于类的对齐矩阵形式表示；
- ◆ 对齐模板自动获取，所有可能的模板都保留，但概率不同。如，模板：

2006年3月15日关于假冒... → X 关于假冒...

11.2.6 基于短语的翻译模型

◆ 用反向的翻译模型
替代正向的翻译模
型: $p(e|f)$

T3	.	.	■	■	■
T2	.	■	.	.	.
T1	■	.	.	.	.
	S1	S2	S3	S4	S5

T1: zwei, drei, vier, fünf, ...

T2: Uhr

T3: vormittags, nachmittags, abends, ...

S1: two, three, four, five, ...

S2: o'clock

S3: in

S4: the

S5: morning, evening, afternoon, ...





11.2.6 基于短语的翻译模型

- ◆ 基于最大熵的方法(ME Approach)[Och, 2002等]
 - 反向的翻译模型用噪声信道模型无法解释。
 - 对于一个随机事件，假设已经有了一组样例，我们希望建立一个统计模型来模拟这个随机事件的分布。
 - 选择一组特征，使得统计模型在这一组特征上与样例中的分布完全一致，同时保证这个模型尽可能的“均匀”(使模型的熵值达到最大)。

11.2.6 基于短语的翻译模型



- 假设 T 、 S 分别是目标语言句子和源语言句子， $h_1(T, S), \dots, h_M(T, S)$ 分别是 T 、 S 上的 M 个特征， $\lambda_1, \dots, \lambda_M$ 是这些特征分别对应的 M 个权值。

对于给定的源语言句子 S , 其最佳译文 T 可以用以下公式表示:

$$\begin{aligned}\hat{e} &= \arg \max_T \{ p(T | S) \} \\ &= \arg \max_T \left\{ \sum_{m=1}^M \lambda_m h_m(T, S) \right\}\end{aligned}$$



11.2.6 基于短语的翻译模型

如果我们将两个特征分别取为 $\log p(T)$ 和 $\log p(S|T)$, 并取 $\lambda_1 = \lambda_2 = 1$, 那么, 这个模型就等价于噪声信道模型, 基于噪声信道模型的方法只是基于最大熵方法的一种特例。最大熵方法中最常用的做法就是采用二值特征。

$$\hat{e} = \operatorname{argmax}_T \left\{ \sum_{m=1}^M \lambda_m h_m(T, S) \right\}$$

11.2.6 基于短语的翻译模型



常用的特征有(以汉英翻译为例):


- ✓ 短语翻译概率
- ✓ 词汇化的短语翻译概率
- ✓ 反向的短语翻译概率
- ✓ 反向的词汇化短语翻译概率
- ✓ 基于 n -gram 的英语语言模型
- ✓ 英语句子长度惩罚
- ✓ 汉语短语个数惩罚

11.2.7 基于短语的翻译 模型的解码算法

11.2.7 短语模型的解码算法



解码算法取决于翻译模型。在基于短语的翻译系统中：




11.2.7 短语模型的解码算法



➤ 代价估算


- 选择候选翻译
- 剪枝



$f =$ 已翻译词所耗费的代价 + 未翻译部分的估算代价

☆ 已翻译词所耗费的代价: 已翻译词的 n -gram 概率

☆ 翻译未来词估计需要的代价: 最大概率或其他因素



11.2.7 短语模型的解码算法

➤ 最大概率:

- ✓ 尚未翻译部分词的正向翻译概率 (汉→英);
- ✓ 尚未翻译部分词的逆向翻译概率 (英→汉);
- ✓ 尚未翻译部分短语的正向翻译概率 (汉→英);
- ✓ 尚未翻译部分短语的正向翻译概率 (英→汉)。

$$TP(\tilde{f}_{start}^{end}) = \max \sum \lambda_i \times \log(p_i(\tilde{e}, \tilde{f}))$$

➤ 其他因素:

- ✓ 译文短语的长度、语言模型概率等。



11.2.7 短语模型的解码算法

➤ 柱搜索(**beam search**) [Ney, 1992; Tillmann, 2003]

基本思想：给定一个输入句子，生成对应的短语序列，每个短语对应一组翻译候选，短语序列按从左到右的顺序或目标短语生成的先后顺序搜索最可能的翻译假设(**hypothesis**)。

采用适当的剪枝策略。

11.2.7 短语模型的解码算法



➤ 以汉英翻译为例：

我	不	喜欢	喝	咖啡
<u>I</u>	<u>no</u>	<u>like</u>	<u>drink</u>	<u>coffee</u>
<u>me</u>	<u>not</u>	<u>like to</u>	<u>drinking</u>	
	<u>do not</u>		<u>drinking coffee</u>	
<u>I</u>	<u>do</u>	<u>not</u>	<u>like to</u>	<u>drink</u>
<u>I</u>	<u>do</u>	<u>not</u>	<u>like to</u>	
...	...			

11.2.7 短语模型的解码算法



➤ 所有翻译候选被存放在一个表里:

我: (1, 1), I, 0.813

我: (1, 1), me, 0.187

我不: (1, 2), I do not, 0.435

我不: (1, 2), I am not, 0.418

我不: (1, 2), I never, 0.147

我不喜欢: (1, 3), I do not like to, 0.532

... ..


不: (2, 2), no, 0.352

不: (2, 2), not, 0.355

不: (2, 2), do not, 0.293

11.2.7 短语模型的解码算法


➤ 从左到右扩展翻译假设：



11.2.7 短语模型的解码算法



- 根据当前状态下被翻译(覆盖)的源语言单词的个数，将翻译假设放入不同的堆栈：



如果栈内的假设数太多，采用适当的策略剪枝：

- ◆ 根据翻译阈值
- ◆ 根据柱容量
- ◆ 根据观察分值

11.2.7 短语模型的解码算法



- (1) 初始化假设栈HypoStack[0 .. nf];
- (2) 创建初始假设hyp_init; 将假设压入栈HypoStack[0]
- (3) 从 $i=0$ 到 $i = nf-1$ 执行如下循环:
 对于栈HypoStack[i]中的每个假设hx 执行如下循环{
 对于 hx 可生成的每个新假设new_hx 执行操作 {
 $nf[new_hx] =$ 被new_hx 覆盖的源语言单词个数;
 把新假设new_hx 压栈hypoStack[nf[new_hx]];
 对栈HypoStack[nf[new_hx]]进行剪枝; } }
- (4) 从栈HypoStack[nf] 中找到最好的假设best_hyp;
- (5) 输出产生best_hyp 的最佳路径。

11.2.7 短语模型的解码算法



➤ 译文生成:

从最后一个栈中找到概率最大的 Hypothesis, 根据其指向父亲节点的指针向前回溯。可以产生 *n*-best 翻译结果。

➤ Pharaoh 解码器 [Koehn, 2003]

<http://www.isi.edu/licensed-sw/pharaoh/>

➤ Moses 解码器

<http://www.statmt.org/moses/>

11.2.8 基于短语模型的 SMT系统实现

11.2.8 基于短语的SMT系统实现



以基于短语的统计翻译系统实现为例。

原文：

他

将

于

4 月

10日

访问

美国

短语划分：

他将

于4月10日

访问美国

翻译：

He will

on April 10

visit America

调整顺序：

He will

visit America

on April 10



11.2.8 基于短语的SMT系统实现



1. 可利用的工具

(1) 语料预处理工具

➤ 工具: EGYPT- TokenizeE.perl.tmpl

<http://www.clsp.jhu.edu/ws99/projects/mt/toolkit/>

➤ 汉语分词工具 一隆重推荐 Urheen:

<http://www.nlpr.ia.ac.cn/cip/software.htm>

(2) 语言模型:

✓ SRI LM: <http://www.speech.sri.com/projects/srilm/>

✓ CMU-Cambridge LM

<http://mi.eng.cam.ac.uk/~prc14/toolkit.html>

11.2.8 基于短语的SMT系统实现



- 词对齐工具: **GIZA++**

<http://www.fjoch.com/GIZA++.html>

- 解码器:

- ✓ Pharaoh / Moses

- ✓ ReWrite

- <http://www.isi.edu/licensed-sw/rewrite-decoder/>

- EM 最小错误率参数训练工具

<http://www.cs.cmu.edu/ashish/mer.html>

11.2.8 基于短语的SMT系统实现



2. 语料准备

- 大规模双语句子级对齐语料
- 目标语言句子

3. 语料预处理

- 汉语分词、全角转半角等
- 英语词汇化、大小写转换、标点分离

4. 词语对齐

利用词对齐工具：**GIZA++**

11.2.8 基于短语的SMT系统实现



5. 短语抽取和概率计算

银行 和 保险 公司 | banks and insurance companies |

1; 0.106; 1; 0.026

坚持 改革 开放 | of reform and opening up |

0.333; 0.001; 1; 0.014

4个常用的概率:

(1) 英汉短语翻译概率

$$p(\tilde{c} | \tilde{e}) = \frac{N(c, e)}{\sum_{\tilde{c}'} N(\tilde{c}', \tilde{e})}$$

11.2.8 基于短语的SMT系统实现



(2) 英汉词汇化的翻译概率

$$\text{lex}(c_1^J \mid e_1^I, a) = \prod_{j=1}^J \frac{1}{|\{i \mid (j, i) \in a\}|} \sum_{\forall (j, i) \in a} p(c_j \mid e_i)$$

(3) 汉英短语翻译概率 $p(\tilde{e} \mid \tilde{c})$

(4) 汉英词汇化的翻译概率 $\text{lex}(\tilde{e} \mid \tilde{c})$

11.2.8 基于短语的SMT系统实现



6. 语言模型训练


- 可采用 **SRILM** 等工具

7. 解码器实现

8. 输出后处理

- 汉语分词空格的去除
- 英语大小写转换、标点处理

11.2.12 译文评估方法



11.2.12 译文评估方法

□ 常用的评测指标

◆ 主观评测： (1)流畅度； (2)充分性；
(3) 语义保持性。


流畅性	
5	完美的英语表达(Flawless English)
4	较好的英语表达(Good English)
3	非母语的英语表达(Non-native English)
2	不流畅的英语表达(Disfluent English)
1	无法理解的英语表达(Incomprehensible)

11.2.12 译文评估方法



充分性	
5	全部信息都已充分表达了出来 (All information)
4	绝大部分信息已经表达了出来 (Most information)
3	很多信息被表达了出来 (Much information)
2	表达了少量信息 (Little information)
1	没有表达任何信息 (None)

* 2004年日本ATR组织口语翻译评测(IWSLT)评测时使用了“流畅性”和“充分性”这两个标准。



11.2.12 译文评估方法

语义保持性 (meaning maintenance)

0	意思完全相反(Total different meaning)
1	部分语义相同，但引入了误导信息 (Partially the same meaning but misleading information is introduced)
2	部分语义相同，没有引入新的信息 (Partially the same meaning and no new information)
3	意思几乎相同(Almost the same meaning)
4	意思完全相同 (Exactly the same meaning)

* 2005年CMU组织IWSLT评测时除了使用“流畅性”和“充分性”以外，还使用了这一标准。

11.2.12 译文评估方法



◆ 客观评测

- (1) 句子错误率: 译文与参考答案不完全相同的句子为错误句子。错误句子占全部译文的比率。
- (2) 单词错误率(**Multiple Word Error Rate on Multiple Reference**, 记作 **mWER**): 分别计算译文与每个参考译文的编辑距离, 以最短的为评分依据, 进行归一化处理。


11.2.12 译文评估方法



(3) 与位置无关的单词错误率 (Position independent mWER, 记作mPER): 不考虑单词在句子中的顺序

(4) METEOR 评测方法

对候选译文与参考译文进行词对齐, 计算词汇完全匹配、词干匹配、同义词匹配等各种情况的准确率 (P)、召回率 (R) 和 F 平均值



11.2.12 译文评估方法

(5) **BLEU**评价方法 [Papineni, 2002]

— **BiL**ingual **E**valuation **U**nderstudy, IBM

➤ 基本思想:

将机器翻译产生的候选译文与人翻译的多个参考译文相比较，越接近，候选译文的正确率越高。

➤ 实现方法:

统计同时出现在系统译文和参考译文中的 n 元词的个数，最后把匹配到的 n 元词的数目除以系统译文的单词数目，得到评测结果。

11.2.12 译文评估方法



例如：

- 系统译文： the the the the the the the.
- 参考译文1： The cat is on the mat.
- 参考译文2： There is a cat on the mat.

按照上述计算方法，如果 n 取1的话，该候选译文可以得到 7/7 的打分，但显然这种翻译结果几乎没有任何意义。



11.2.12 译文评估方法

修正的计算一元语法精确度的方法：针对某个待评测的系统译文句子，首先统计每个单词在所有参考译文中出现次数的最大值 Max_Ref_Count ，然后，统计该单词在系统译文中出现的总次数 $Count$ ，取 $Count$ 和 Max_Ref_Count 两者中小的一个，即

$$Count_{clip} = \min(Count, Max_Ref_Count)$$

这样保证了每个系统译文中的单词计数不会超过该词在某个参考译文中出现次数的最大值。

11.2.12 译文评估方法



把系统译文中所有单词的 $Count_{clip}$ 值累加起来，得到 $Total_Count_{clip}$ ，即待评测的系统译文中出现在参考译文中的单词个数，最后，用 $Total_Count_{clip}$ 除以系统译文中全部单词的个数。在上面的例子中，系统译文中的单词the在参考译文1中出现的次数最多， $Max_Ref_Count=2$ ，而the在系统译文中出现的次数为7，即 $Count=7$ ，因此， $Count_{clip}=\min(7, 2)=2$ 。候选译文中全部单词的个数等于7，因此，该例中修正后的一元语法精确度为 $2/7$ 。请再看下面的例子：

11.2.12 译文评估方法



候选译文: It₁ is₂ a₃ guide₄ to₅ action₆ which₇ ensures₈ that₉ the₁₀ military₁₁ always₁₂ obeys₁₃ the₁₄ commands₁₅ of₁₆ the₁₇ party₁₈.

参考译文1: It is a guide to action that ensures that the military will forever heed Party commands.

参考译文2: It is the guiding principle which guarantees the military forces always being under the command of the Party.

参考译文3: It is the practical guide for the army always to heed the directions of the party.

单词1~6, 8~11, 14~15, 17~18 均出现在参考译文1中, 第7个单词出现在参考译文2中, 第12、16个单词均出现在译文2和3中。只有第13个词没有出现在任何译文中。

11.2.12 译文评估方法



因此，一元语法精确度为：17/18。

如果考虑 bi-gram {(it is), (is to), (to insure) ...}，那么，修正的2元语法的精度为：10/17。

对于含多个句子的测试文本，以句子为单位分别计算 n -gram 的匹配情况，然后，累计所有翻译句子修正后的 n -gram 计数，及测试集的所有 n -gram 计数，二者相除，得到修正后的精确度记分：

$$p_n = \frac{\sum_{C \in \{\text{Candidate}\} s \text{ } n\text{-gram} \in C} \sum \text{Count}_{clip}(n\text{-gram})}{\sum_{C' \in \{\text{Candidate}\} s \text{ } n\text{-gram}' \in C'} \sum \text{Count}(n\text{-gram}')}$$



11.2.12 译文评估方法

考虑到在修正的 n 元语法精度计算中，随着 n 值的增大精度值几乎成指数级下降，因此，BLEU方法中采用了修正的 n 元语法精度的对数加权平均值，相当于对修正的精度值进行几何平均， n 值最大为4。

另外，考虑到句子的长度对上述BLEU评分也有一定的影响，例如，如果一个机器翻译系统只翻译最可靠的词汇，译文句子就可能比较短，按上述方法计算出的精度值就会较高。因此，需要进一步考虑候选译文的句子长度对计算评分的影响。

11.2.12 译文评估方法



$$BLEU = BP \times \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

最大语法的阶数，实际取4。

出现在答案译文中的 n 元词语接续组占候选译文中 n 元词语接续组总数的比例。

$w_n = 1/N$

长度过短句子的惩罚因子

$$BP = \begin{cases} 1 & \text{if } c > r \\ e^{(1-r/c)} & \text{if } c \leq r \end{cases}$$

c 为候选译文中单词的个数， r 为答案译文中与 c 最接近的译文单词个数。

BLEU 分值范围：0 ~ 1，分值越高表示译文质量越好，分值越小，译文质量越差。

本讲小结



- 统计机器翻译的基本原理
- IBM 1~5 翻译模型
- 翻译模型的改进
- 解码算法
- SMT 系统实现方法
- 译文评估方法